

이슈보고서

혁신성장금융1부

VOL.2026-이슈 (2026.8)

데이터센터용 AI반도체 시장 현황 및 전망



CONTENTS

<요약>

- I. AI반도체 시장 현황 및 전망
- II. 주요 기업 및 향후 전망
- III. 한국의 AI반도체 산업 현황
- IV. 결론 및 시사점

작성

선임연구원 이미혜 (6255-5404)




< 요약 >

I. AI반도체 시장 현황 및 전망

시스템반도체의 차세대 성장동력인 AI반도체 시장은 2024년 1,830억 달러에서 2030년 1조 달러로 연평균 33% 성장할 전망

- 데이터센터용 AI반도체 시장은 2024년 1,240억 달러에서 2030년 8,600억 달러로 연평균 38% 성장할 전망
- 온디바이스용 AI반도체 시장은 2024년 592억 달러에서 2030년 1,430억 달러로 연평균 16% 성장할 전망

AI반도체 시장 전망



자료: 옴디아.

데이터센터용 AI반도체 시장은 엔비디아가 독점적 지위를 유지하는 가운데 구글, AMD, 인텔, 화웨이 등이 엔비디아를 추격중

- 데이터센터용 AI반도체 시장점유율('25)은 엔비디아가 78.2%로 지배적 지위를 유지하며, 다음으로 구글 4.7%, AMD 4.1%, 인텔 3.7%, 화웨이 2.6%, AWS 2.2% 순
- 하이퍼스케일러는 데이터센터 비용 절감, 기술 주도권 및 공급망 안정성 확보 등을 위해 Custom ASIC을 개발하고 자사 데이터센터에 적용
- AI반도체 스타트업은 추론 시장을 타겟으로 다양한 기술이 적용된 칩을 개발중이며, 기업별로 초기 상용화 검증 단계에서 본격 상용화 단계까지 편차를 보임



Agentic AI의 확산과 추론 워크로드의 증가로 데이터센터의 효율성을 제고하기 위해 이기종 칩을 활용한 분산 추론(Heterogeneous Inference) 도입이 확산될 전망

- AI 추론은 연산 집약적인 Prefill(입력 프롬프트 처리) 단계와 데이터 전송 속도가 중요한 메모리 대역폭 집약적인 Decode(토큰 생성) 단계로 나뉨
- 추론 인프라는 추론 단계별 자원 병목 해소, 비용 절감 등을 위해 동종 AI반도체 기반의 분산 추론에서 이기종 분산 추론으로 고도화되고 있음

II. 주요 기업 및 향후 전망

엔비디아는 AI Factory 전략하에 GPU 중심 기업에서 AI 구현에 필요한 하드웨어(칩), 소프트웨어, 통신 등을 통합 제공하는 AI 인프라 플랫폼 기업으로 진화

- 엔비디아는 1993년에 설립된 이후 20년 이상 GPU를 개발했으며 2006년에 발표한 CUDA (Compute Unified Device Architecture)를 통해 강력한 진입장벽을 형성
- 엔비디아는 사업영역을 GPU에서 네트워크, CPU, DPU(Data Processing Unit) 등으로 확대한데 이어 전력 표준 등을 제시하며 AI 인프라 플랫폼 기업으로 도약
- 엔비디아는 경쟁력을 유지하고 생태계를 강화하기 위해 고객사 다변화, 잠재고객인 AI 기업 육성, NVLink 생태계 개방 등을 추진

AMD는 사업모델을 칩에서 Rack-scale 솔루션으로 확장하고, 엔비디아의 폐쇄적 생태계에 대응하여 개방형 생태계 구축하면서 엔비디아를 추격

- AMD는 CPU와 GPU 시장에서 각각 인텔과 엔비디아에 이어 2위로 칩 포트폴리오 강화, GPU 출시 주기 단축 및 성능 향상 등을 통해 엔비디아를 추격중
- AMD는 Open Compute Project의 표준에 맞춰 설계된 개방형 AI 레퍼런스 플랫폼 Helios Rack Scale 디자인을 공개하며 사업모델을 칩에서 Rack 단위로 확장

구글이 출시한 AI ASIC TPU는 AI ASIC 중 가장 성공한 사례로, 구글은 TPU를 자사 클라우드를 통해 외부에 임대해왔으나 최근 외부 판매로 사업 전략을 변경

엔비디아는 기술, 생태계, 자본 등을 기반으로 지배적 지위를 유지하나 AI 추론 워크로드 다변화와 수요기업의 추론 경제성 확보 노력으로 후발주자의 시장 진입 기회도 확대될 전망



Ⅲ. 한국의 AI반도체 산업 현황

국내 대표 기업은 리벨리온과 퓨리오사AI로 2세대 NPU를 개발하고 상용화 직전 단계에 위치

- 리벨리온은 2020년에 설립되어 데이터센터를 타겟으로 2024년에 ATOM을 출시했으며, 2026년 하반기에 2세대 칩 REBEL 100을 출시할 계획
- 퓨리오사AI는 2017년에 설립되었으며 2023년에 1세대 칩 Warboy 양산, 2026년초부터 2세대 칩 레니게이드(RNGD) 양산을 시작
- 우리 기업은 칩 설계 기술력은 갖추었으나 선도기업과 자본, 상용화 경험, 생태계 등에서 격차가 있음
- 미국, 중국 등 소수 국가만이 상용 수준의 AI반도체를 개발했으며, 한국의 AI반도체 설계 기술은 선도국인 미국 대비 3년 수준의 기술격차가 있음
- 인터커넥트, 첨단 패키징, Full-stack 시스템 아키텍처 수준에서는 선도국과 기술격차가 3년 이상

2025년 12월 18일, 정부는 'AI 반도체 산업 도약 전략'을 수립하고 K-엔비디아 육성을 통해 2030년까지 글로벌 AI반도체 유니콘 기업 5개사 창출을 목표로 설정

- 2026년 3월, 국민성장펀드는 향후 5년간 50조원을 AI·반도체 분야에 투자할 계획을 발표했으며, 이후 리벨리온, 퓨리오사AI, 국가AI컴퓨팅센터 등에 투자
- 과학기술정보통신부는 2025년부터 'AI 반도체 해외실증 지원 사업'을 지원하며, 최근에는 AMD와 국산 NPU를 연계하는 이기종 AI 컴퓨팅 구축실증을 위한 업무협약을 체결

IV. 결론 및 시사점

국산 AI반도체 상용화의 병목은 소프트웨어 최적화 부족과 실사용 환경에서 검증된 운영 실적 부족으로 소프트웨어 Stack 강화와 Reference 구축 지원 확대 등이 필요

2026년은 AI 산업이 추론 중심으로 재편되는 전환점으로 한국 AI반도체 기업은 소버린 AI 프로젝트, AI 추론 비용 효율화를 추진하는 기업 등과 협력할 기회가 있을 전망

- 중동·유럽 등이 국가안보, 지정학적 이슈 등으로 AI반도체 공급처 다변화를 추진하고 있어 한국기업의 해외진출에 대한 정부의 외교적 지원 등이 필요
- AI반도체 시장은 3~5년내에 AI반도체 스타트업의 생사 여부가 결정되고, 업계 통합이 가속화될 것으로 전망되어 우리기업의 조기 Reference 확보가 중요할 전망




I. AI반도체 시장 현황 및 전망

1. AI반도체의 개요

AI반도체는 AI 알고리즘을 효율적으로 실행할 수 있도록 설계된 반도체로 AI 연산 가속(AI Accelerator)이 목적인 GPU, FPGA, ASIC을 포함

- AI 연구 초기에는 CPU를 사용했으나 딥러닝 등장 이후 데이터의 양과 매개변수의 수가 증가하면서 GPU(Graphic Processing Unit)가 사용됨
 - CPU(Central Processing Unit)는 컴퓨터의 주 연산장치로 복잡한 연산을 순차적(sequential)으로 처리하여 대량의 데이터 연산에 긴 시간이 소요됨
 - GPU는 단순 계산을 병렬(parallel)로 처리하여 대규모 데이터 처리에 효율적이며, 범용성(Flexibility)이 높아 다양한 AI 알고리즘을 사용할 수 있음
 - 그러나 GPU는 그래픽 처리를 위해 개발된 프로세서로 AI 연산에 최적화된 구조가 아니어서 전력소모가 큰 단점이 있음
- GPU를 보완하기 위해 AI의 특정 연산에 특화된 FPGA(Field-Programmable Gate Array), ASIC(Application Specific Integrated Circuit)의 사용이 증가
 - FPGA는 소프트웨어를 업데이트해 용도에 맞게 내부 회로를 바꿀 수 있는 반도체로, 데이터센터용 AI반도체 수요가 GPU와 ASIC의 강점에 집중해 성장성이 제약을 받음
 - ASIC은 특정 AI 알고리즘에 특화된 반도체로 범용성이 낮으나 저전력 등이 장점이며 대표적인 프로세서는 NPU(Neural Processing Unit, 신경망처리장치)
 - NPU는 인공지능 연산에 특화된 반도체로 다른 AI 알고리즘 사용시 최적화 수준이 낮거나 추가적이 변환·최적화 과정이 필요
 - TPU(Tensor Processing Unit)는 텐서 연산, LPU(Language Processing Unit)는 LLM 처리에 최적화된 NPU 계열 ASIC

AI 구현에 사용되는 반도체





※ 참고: 딥러닝 신경망 알고리즘의 변화

- 딥러닝의 주류 인공지능망 알고리즘은 CNN(Convolutional Neural Network), RNN(Recurrent Neural Network)에서 Transformer로 진화
- CNN(Convolutional Neural Network, 합성곱 신경망)은 이미지 인식 분야에서 뛰어난 성능을 발휘하는 알고리즘으로 객체인식, 분류 등의 작업에 활용
- RNN(Recurrent Neural Network, 순환신경망)은 입력 노드에서 출력 노드까지 한 방향으로 시간 순서에 따라 데이터를 처리하여 문장, 시계열 데이터 등의 처리에 특화된 모델임
순차적 데이터 처리로 연산속도가 느리고, 긴 문장 번역시 오역이 증가하는 단점 발생
- Transformer는 2017년 구글이 제시한 딥러닝 아키텍처로 Self-Attention 매커니즘을 핵심 연산으로 채택해 문장 내 단어 간 상관관계를 가중치로 학습
RNN(순환 신경망)의 한계를 극복하기 위해 문장 전체를 병렬구조로 처리하여 텍스트와 음성을 거의 실시간으로 옮김
Transformer는 현재 대규모 언어모델(LLM)의 표준 아키텍처로 자리잡음

AI반도체는 서비스 플랫폼에 따라 데이터센터용과 온디바이스용, 사용 목적에 따라 학습용(Training)과 추론용(Inference)으로 분류

- AI반도체는 서비스 플랫폼에 따라 데이터센터용(서버용)과 온디바이스용으로 분류
 - 데이터센터용 AI반도체는 연산 성능과 저전력 소비 등이 중요
 - 온디바이스용 AI반도체는 스마트폰, 자동차, 드론 등에 사용되며 저전력, 가격, 크기 등이 핵심 경쟁요소
- 학습은 대량의 데이터를 기반으로 AI 모델을 개발, 추론은 AI 모델을 기반으로 서비스를 제공
 - 학습용 AI반도체는 주로 클라우드¹⁾에서 사용되며 연산성능 등이 중요해 GPU 중심
 - 추론용 AI반도체는 클라우드와 디바이스에서 모두 사용되며 정확도, 저지연성 등이 중요하며 CPU, GPU, NPU가 사용됨
 - 추론용 반도체는 사용되는 디바이스별로 필요한 연산 능력이 다양함

1) 클라우드 컴퓨팅은 하드웨어, 소프트웨어 등의 정보자원을 직접 구축·운영하지 않고 네트워크에 접속해 이용하는 기술로 이용자가 사용한 만큼 과금되는 구조




2. 시장규모

시스템반도체의 차세대 성장동력인 AI반도체 시장은 2024년 1,830억 달러에서 2030년 1조 달러로 연평균 33% 성장할 전망²⁾

- 데이터센터용 AI반도체 시장은 2024년 1,240억 달러에서 2030년 8,600억 달러로 연평균 38% 성장할 전망
- AI 패권 확보를 위해 하이퍼스케일러가 투자를 확대하는 가운데 Neo Cloud, 주요국의 소버린 AI 투자 등이 이어지면서 2030년 데이터센터 CAPEX는 1.6조 달러에 이를 전망
 - Neo Cloud는 GPU 중심의 AI에 특화된 클라우드로 시장조사기관 가트너는 Neo Cloud가 2030년 AI 클라우드 시장점유율 20%를 차지할 것으로 전망
 - 주요국은 AI를 안보와 산업 경쟁력 확보를 위한 핵심 산업으로 인식하고 데이터 주권 확보, AI 산업 육성 등을 위해 소버린 AI를 추진
 - * 주요 소버린 AI 프로젝트는 미국의 Stargate, EU의 AI Factory, UAE의 G42와 Stargate UAE 등이며, 소버린 AI의 투자규모('25~'29)는 7~8조 달러 이상으로 추정됨
- 온디바이스용 AI반도체 시장은 2024년 592억 달러에서 2030년 1,430억 달러로 연평균 16% 성장할 전망
- AI PC 등의 보급 확대, 자동차의 자율주행 기능 강화 등이 성장을 견인할 전망

AI반도체 시장규모 전망

단위: 억 달러



자료: 옴디아, 수출입은행.

2) AMD는 AI반도체 시장이 2030년에 1.4조 달러 규모로 성장할 것으로 전망(2026.7)




3. 경쟁구도

데이터센터용 AI반도체 시장은 엔비디아가 독점적 지위를 유지하는 가운데 구글, AMD, 인텔, 화웨이 등이 엔비디아를 추격중

- 데이터센터용 AI반도체 시장점유율('25)은 엔비디아가 78.2%로 지배적 지위를 유지하며, 다음으로 구글 4.7%, AMD 4.1%, 인텔 3.7%, 화웨이 2.6%, AWS 2.2% 순
- 화웨이는 미국의 AI반도체 수출 규제, 중국 정부의 AI산업 육성 정책 등에 힘입어 내수 시장을 중심으로 시장점유율을 확대
- AI반도체 스타트업의 시장점유율은 Cerebras(미)가 0.7%로 가장 높으며, 다음으로 캄브리콘(중) 0.4%, Groq(미) 0.2% 순으로 아직은 존재감이 미미함
- 엔비디아의 데이터센터 매출은 견조한 성장세를 유지하고 있으며, AMD와 인텔의 데이터센터 관련 부문 매출은 엔비디아 매출의 1/7 수준으로 격차가 있음
- GPU 시장점유율('25)은 엔비디아 92%, AMD 8%이며, 인텔의 점유율은 1% 미만
- CPU 시장점유율('26.1분기)은 인텔 58%, AMD 29%, Arm IP 기반 CPU 13%
 - 엔비디아와 하이퍼스케일러가 Arm 기반 CPU를 지속적으로 출시하고 있음

데이터센터용 AI반도체의 시장점유율



자료: 옴디아.



하이퍼스케일러는 데이터센터 비용 절감, 기술 주도권 및 공급망 안정성 확보 등을 위해 Custom ASIC을 개발하고 자사 데이터센터에 적용

- 하이퍼스케일러는 칩 비용 절감, 자사 AI 모델과 클라우드에 최적화된 칩 개발, 칩 공급망 안정성 확보 등을 위해 자체 칩(Custom ASIC)을 개발
- 하이퍼스케일러는 엔비디아의 최대 고객으로, 자사에 최적화된 칩을 개발하여 엔비디아 의존도 축소 및 가격협상력 확보, 데이터센터 구축·운영 비용 절감 등을 추진
 - 엔비디아의 매출총이익률은 70% 이상이며, GPU는 범용성을 확보하는 대신 전력 소모가 큼
- 하이퍼스케일러의 AI반도체 개발은 추론용 NPU 중심이며, 자사 AI 모델(구글의 제미나이, Meta의 라마 등)에 최적화된 칩을 개발하여 서비스 차별화를 추진
 - 구글의 TPU(Tensor Processing Unit)는 자사의 딥러닝 프레임워크 TensorFlow에 최적화되어 있으며, 구글 TPU는 칩이 진화되면서 학습용과 추론용으로 분리됨
- 구글과 아마존은 자체 칩 사용을 확대할 계획이며, 자체 칩 생태계 조성이 상대적으로 더딘 메타, 마이크로소프트 등은 엔비디아 의존도가 높음
- 하이퍼스케일러는 AI반도체 스타트업 인수와 협력, 반도체 설계 서비스 파트너와 협력(Co-Designer) 등을 통해 자체 칩을 개발
 - 아마존은 이스라엘의 Annapurna Labs, Meta는 미국 Rivos 등을 인수하여 반도체 설계 역량을 강화
 - 하이퍼스케일러가 칩 설계 역량을 확보했더라도 브로드컴, 마벨(Marvell Technology) 등 반도체 설계 서비스 파트너와 협력하여 칩 개발 속도와 실행 가능성을 제고

주요 기업의 AI반도체 스타트업 인수 현황

	인수기업	피인수/협력 기업	비고
2015	아마존	Annapurna Labs	이스라엘 팹리스
2016	인텔	Nervana Systems	미국 AI반도체 스타트업
2020	인텔	하바나랩스	이스라엘 팹리스
2024	소프트뱅크	그래프코어	영국 AI반도체 스타트업
2025	엔비디아	Groq	우회 인수(기술 라이선스와 핵심 인력 확보)
2025	메타	Rivos	오픈소스 기반의 RISC-V 아키텍처 칩 설계
2025	AMD	Untheter AI	캐나다 AI반도체 기업의 엔지니어링팀을 인수

자료: State of AI, 뉴스.



ASIC 설계 서비스는 브로드컴이 글로벌 시장점유율 60~70%로 시장을 주도하며, 마벨, 미디어텍 등이 브로드컴을 추격중

- 브로드컴은 최대 고객은 구글이며, Meta, 오픈AI 등을 고객으로 확보
- 브로드컴은 칩 설계 뿐만 아니라 반도체 전체 공정을 총괄하는 Turnkey 서비스³⁾와 AI 인프라의 병목으로 지적되는 네트워크 기술(스위치 등) 등을 제공
 - 칩 설계 수수료(Non-Recurring Engineering, NRE)와 양산 물량과 연동되는 로열티/판매 수익, IP 사용료 등을 받으며, 자사의 네트워킹 제품(이더넷 스위치 등) 등을 함께 판매
- 구글과 2031년까지 TPU 개발 및 이를 구동하기 위한 네트워킹 및 관련 부품 공급 계약을 체결
- 마벨의 주요 고객은 AWS와 마이크로소프트이며, 엔비디아와 협력을 통해 ASIC 설계 서비스 시장 입지 강화를 추진
- 마벨은 2028년 ASIC 설계 서비스 시장점유율 목표를 20%로 수립했으며, 자사 ASIC이 엔비디아 시스템과 호환될 수 있도록 엔비디아가 주도하는 NVLink Fusion에 참여
- 하이퍼스케일러는 공급망 리스크 분산, 협상력 확보 등을 위해 ASIC 설계 파트너 다변화를 추진
- 구글은 브로드컴의 반도체 솔루션 부문 매출총이익률이 70% 내외로 엔비디아의 매출 총이익율에 육박하는 수준을 기록하고 있어 주요 기업은 설계 파트너 다변화를 추진
- 미디어텍은 구글 TPU 수주 등으로 2027년 ASIC 시장점유율 목표를 15~20%로 수립

Co-Designer의 Custom ASIC 프로젝트(2026~2028)

브로드컴	마벨	GUC	알칩	미디어텍
·TPU v7(Ironwood)	·Trainium 2	·Maia 200	·Trainium 3	·TPU v8i
·TPU v8t(Sunfish)	·Maia 300		·Trainium 4	·TPU v9
·TPU v9				(Triggerfish)
·MTIA 400				
·오픈AI Titan v1				
·Titan v2				
·Titan v3				
·xAI의 X1				
·소프트뱅크 Izanagi 1				
·소프트뱅크 Izanagi 2				

주: TPU는 구글, Trainium은 아마존, MTIA는 메타, Titan은 OpenAI가 자기 칩에 붙인 브랜드명
자료: 트렌드포스('26.4).

3) IP 제공, 파운드리 위탁생산, HBM 조달, 패키징, 테스트까지 전체 공정을 총괄




AI반도체 스타트업은 추론 시장을 타겟으로 다양한 기술이 적용된 칩을 개발중이며, 기업별로 초기 상용화 검증 단계에서 본격 상용화 단계까지 편차를 보임

- GPU와 주류 ASIC은 KV(Key-Value) Cache* 저장에 HBM(High Bandwidth Memory)을 사용하나 Groq 등은 저지연·저전력 구현을 위해 S램(Static Random Access Memory)을 사용

* AI 모델이 응답을 생성하면서 발생하는 중간 연산결과

- GPU의 성능은 2년마다 3배 발전했으나, D램의 데이터 전송속도(Bandwidth)는 2년간 1.6배 개선되면서 GPU와 메모리간 데이터 전송속도 차이로 병목현상 발생(Memory Wall)
- Memory Wall을 극복하기 위해 GPU와 주류 ASIC은 메모리 대역폭과 용량을 확대한 HBM(고대역폭 메모리)을 사용하나 고비용 등의 단점이 있음
 - Batch 크기가 작고 저지연이 중요한 요청은 GPU의 대규모 병렬처리의 장점을 충분히 활용하기 어려워 활용률이 낮아지고, 토큰당 비용이 상승
- Groq과 세레브라스는 연산 과정에서 빈번하게 사용되는 데이터를 고가의 HBM 대신 On-Chip 메모리⁴⁾인 S램에 상주시켜 데이터 이동을 최소화하고 전력효율을 개선
 - 세레브라스는 웨이퍼 한 장을 통째로 하나의 칩으로 사용하며, WSE-3은 44GB의 S램을 탑재

Memory Wall



자료: 트렌드포스.

메모리 계층 구조



자료: SK하이닉스

4) 메모리가 연산 유닛과 동일 칩 내에 위치



- Hard-Wired 칩은 AI 모델의 가중치와 알고리즘을 칩 내부의 하드웨어 구조로 새겨넣은 초저지연·저전력 AI반도체이나 AI 모델 아키텍처가 급변하면 칩을 사용하기 어려움
- Taalas는 AI 모델 가중치를 HBM이나 D램에 저장하지 않고 실리콘 상에 Mask ROM (Read-Only Memory)에 새겨 메모리 병목 현상을 제거하고, KV 캐시는 HBM 대신 S램에 저장하여 저지연을 구현
 - Taalas의 HC1은 HBM과 첨단 패키징을 사용하지 않아 AI반도체 공급망 병목을 우회
- Etched는 Transformer 알고리즘만을 구동할 수 있는 칩을 개발(Transformer 전용 ASIC)
- Computing in Memory(CIM)는 데이터를 메모리에서 프로세서로 이동시키지 않고 메모리 내부에서 직접 연산을 수행하여 데이터 전송에 따르는 지연 시간과 에너지 소모를 방지
- 텐스토렌트는 오픈소스 기반의 명령어 집합구조(ISA)인 RISC-V를 채택해 유연성과 저비용 등에 장점이 있음
- RISC-V는 미국 UC버클리에서 개발한 무료 오픈소스 RISC 아키텍처로 특정 국가의 수출 통제나 특정 기업의 지적재산권(IP) 독점 행위로부터 자유로움

AI반도체 스타트업의 추론칩 비교

기술 유형		SRAM First	Wafer Scale Integration	계층형 메모리	Hard-Wired		Computing in Memory (CIM)	RISC-V	Tensor Contraction Processor
회사		Groq (미국)	세레브라스 (미국)	삼바노바 (미국)	Taalas (캐나다)	Etched (미국)	d-Matrix (미국)	텐스토렌트 (캐나다)	퓨리오사AI (한국)
AI 칩		LPU	WSE-3	SN50	HC1	Sohu	Corsair	Blackhole	RNGD
칩 크기		725 mm²	46,225 mm²	-	815 mm²	800 mm²	3,200 mm²	620 mm²	-
메모리 아키텍처	S램	80 TB/s; 230MB	21 PB/s; 44GB	432MB	- (Mask ROM+S램)	-	150 TB/s; 2GB	180MB	384 TB/s; 256MB
	D램	-	-	DDR5 2TB		-	LPDDR5 256 GB	GDDR6 32 GB	-
	HBM	-	-	HBM2E 64 GB		HBM3E 144GB	-	-	HBM3 48 GB

자료: 트렌드포스.




4. 주요 트렌드

Agentic AI의 확산과 추론 워크로드의 증가로 데이터센터의 효율성을 제고하기 위해 이기종 칩을 활용한 분산 추론(Heterogeneous Inference) 도입이 확산될 전망

- AI 추론은 연산 집약적인 Prefill(입력 프롬프트 처리) 단계와 데이터 전송 속도가 중요한 메모리 대역폭 집약적인 Decode(토큰 생성) 단계로 나뉨
 - Prefill은 사용자가 입력한 프롬프트를 읽고 이해하는 과정으로 대량의 행렬 연산을 동시에 처리하여 연산 성능이 중요(Compute bound)
 - Decode는 Prefill 단계에서 생성된 중간 연산값 KV(Key Value) Cache를 메모리에서 GPU로 전송되는 속도가 지연시간을 결정하여 메모리 대역폭이 중요(Memory bound)
- 추론 인프라는 추론 단계별 자원 병목 해소, 비용 절감 등을 위해 동종 AI반도체 기반의 분산 추론에서 이기종 분산 추론으로 고도화
 - 기존에는 단일 GPU에서 Prefill과 Decode를 모두 처리했으나, 동시 사용자수 증가 등에 따른 대량의 Prefill 요청은 토큰 생성에 지연을 초래
 - 2024년에 Prefill과 Decode의 하드웨어를 분리하는 분산 추론 아이디어를 소개한 논문이 발표되었으며⁵⁾, 2025년초에 공개된 DeepSeek의 추론모델 R1은 분산 추론을 사용
 - 동종 칩을 사용해도 Prefill과 Decode를 물리적으로 분리하면 자원 병목이 해소됨
 - 최근에는 추론 단계별 특성에 맞는 칩을 사용하는 이기종 분산 추론(예: Prefill은 GPU, Decode는 NPU)이 본격화되고 있음

AI 추론 패러다임의 변화



자료: Cerebras, 수출입은행.

5) Zhong et al., 'DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving' OSDI 2024



주요 기업이 Agentic AI 지원 등을 위해 이기종 분산 추론 체제 구축을 본격화

- 엔비디아는 Vera Rubin 플랫폼에서 Prefill과 Decode의 Attention 연산은 GPU, Decode의 Feed-Forward Network(FFN, 순방향 신경망) 연산에 Groq의 LPU를 도입
- Transformer 기반 LLM 추론은 Attention과 Feed-Forward Network(FFN, 순방향 신경망) 연산이 순차 반복되며 토큰을 생성
- Attention은 토큰 간 관계를 분석해 문맥을 파악하는 연산으로, 중간 연산값 KV 캐시를 대량 참조해야 하는 메모리 집약적(Memory bound) 연산으로 HBM을 탑재한 GPU를 사용
- FFN은 모델 가중치를 반복적으로 불러와 처리하는 연산으로 단일 토큰 처리시 빠른 연산이 중요해 S램을 탑재한 LPU를 배치
- AWS는 Prefill은 자체 칩 Trainium, Decode는 Cerebras의 CS-3을 사용하는 협력을 발표했으며('26.3), 2026년 하반기에 아마존 Bedrock에서 서비스를 시작할 예정
- Trainium과 CS-3은 AWS의 고속 네트워크 인터페이스 Elastic Fabric Adapter(EFA)로 연결
- 인텔은 Prefill에 추론에 특화된 자사 GPU Crescent Island('26년 출시 예정), Decode에 AI반도체 스타트업 삼바노바의 RDU(Reconfigurable Dataflow Unit)를 사용할 계획
- Crescent Island는 HBM 대신 LPDDR5X를 탑재하여 칩 가격을 낮춤
- 2026년 7월, AMD는 Cerebras와 이기종 분산 추론 협력을 발표
- 화웨이의 Ascend 950은 950PR(Prefill & Recommendation)과 950DT(Decode & Training)로 구성되며, 각각 2026년 상반기와 하반기에 출시될 예정

이기종 분산 추론을 위한 협력 관계

	Prefill 가속기	Decode 가속기	CPU
엔비디아-Groq	엔비디아 GPU	Groq LPU	엔비디아 CPU
인텔-삼바노바	인텔 GPU	삼바노바 RDU	인텔 Xeon 6
AWS-Cerebras	AWS Trainium	Cerebras CS-3	

자료: TechInsights.

- 분산 추론은 대규모 AI 서비스, Agentic AI, 지연시간 관리, Long-context 워크로드에는 적합하나 시스템 복잡성 증가 등의 위험이 있음
- 분산 추론은 요청 처리가 여러 하드웨어로 이동하게 되면서 네트워크 지연, 장애 발생 지점 증가 등이 발생할 가능성이 높아져 시스템 모니터링 및 운영 난이도가 상승



AI반도체의 경쟁력을 평가하는 지표가 칩의 연산성능에서 전력당 토큰 생산량(Tokens per Watt) 등으로 이동하고, 인프라 구축 단위도 개별 칩 단위에서 Rack 스케일로 이동

- AI 추론 서비스의 증가로 AI 인프라 사업자의 핵심과제는 제한된 전력·비용 조건하에서 다수의 동시 사용자 요청을 얼마나 효율적으로 처리할 수 있는지가 중요
- 생성형 AI 확산 초기인 AI 학습 중심 시대에는 데이터센터 경쟁력이 GPU의 연산성능과 보유 수량으로 평가됨
- AI 추론이 본격화되면서 데이터센터가 한정된 전력 내에서 얼마나 많은 토큰을 생산하느냐가 기업 수익과 직결되어 칩의 성능보다 시스템 전체의 에너지 효율성이 중요
- 초거대 AI 모델의 등장으로 다수의 칩을 고속으로 연결해 하나의 연산 단위로 작동시키는 방식이 요구되었으며, Rack이 AI 인프라의 새로운 운영 단위로 부상
- Rack은 서버, 네트워크 장비, 스토리지 등을 설치 및 보관하는데 사용되는 캐비닛 형태의 구조물로 냉각 등에 핵심 역할을 담당
- 엔비디아는 GTC 2024에서 Rack 전체를 하나의 컴퓨팅 단위로 설계한 'GB200 NVL72'를 공개
 - GB200 NVL72는 72개의 Blackwell GPU와 36개의 Grace CPU에 전력·냉각·소프트웨어를 통합한 시스템으로 Rack 스케일 단위 경쟁의 출발점으로 평가됨
 - 하이퍼스케일러는 GPU를 구매한 후 서버 및 Rack 수준의 시스템을 자체 설계·구축하는 방식이 일반적이었으나 엔비디아가 Rack 스케일 레퍼런스 아키텍처를 제시하자 이를 채택하기 시작
- AMD의 첫 번째 Rack-scale AI 시스템 Helios는 GPU, CPU, 네트워크, 소프트웨어를 하나로 묶었으며, 2026년 7월에 출시되고 연내에 고객에게 인도할 계획
- Agentic AI의 확산과 Rack당 전력밀도의 가파른 상승 등으로 AI 컴퓨팅 경쟁의 축이 단일 Rack 최적화에서 다수의 Rack을 통합·제어하는 POD로 확장
- 생성형AI는 단순 질의응답 구조에 머물렀으나, Agentic AI는 스스로 계획을 수립하고, 여러 단계의 작업을 순차적으로 실행하며, 필요시 다른 AI Agent를 호출하여 협업하는 방식으로 작동해 요구되는 연산량과 컴퓨팅 자원 수요가 폭증
- GPU Rack당 전력밀도⁶⁾는 Hopper 40kW, Blackwell 120kW, VR200 NVL72는 200kW이며, 2027년에 출시될 Rubin Ultra Kyber는 600kW, 이후 세대는 1MW로 확대될 전망
- Rack당 전력밀도가 빠르게 높아짐에 따라 AI 인프라의 설계·운영 단위는 개별 Rack에서 다수의 Rack을 하나의 전력·냉각·네트워크 체계로 통합한 POD 단위로 확장되는 추세

6) 서버 Rack 1개가 소비하는 전력의 양



Frontier AI Lab과 주요 기업은 AI 수요 확대와 소버린 AI 확산으로 컴퓨팅 자원 확보, 비용 효율화, 공급망 안정화 등을 위해 Multi-Cloud, Multi-Chip 전략을 확대

- 오픈AI는 엔비디아 칩 의존도가 높았으나 AMD와 Cerebras의 칩, 브로드컴과 공동 개발한 추론 칩 할라페노 등을 AI 워크로드 성격에 맞게 조합하여 사용할 계획
- 마이크로소프트는 2019년 오픈AI에 10억 달러를 투자하며 오픈AI 클라우드 컴퓨팅 서비스의 독점 공급자가 되었으나, 2026년 4월에 양사는 계약 수정을 통해 독점 공급이 종료됨
- 이후 오픈AI는 오라클 클라우드 컴퓨팅 자원 구매 3,000억 달러⁷⁾, AWS와 1,000억 달러*의 전략적 파트너십을 체결했으며, 구글 클라우드를 통해 TPU를 임대하여 사용
 - * 오픈AI는 2GW의 AWS Trainium 활용 예정이며, 아마존은 총 500억 달러를 오픈AI에 투자 예정
- 2025년 10월에 오픈AI는 AMD와 6GW의 GPU 구매를 위한 전략적 파트너십을 체결
- 2026년 1월, 오픈AI는 Cerebras와 3년간 최대 750MW의 컴퓨팅 파워 공급계약을 체결
- Anthropic은 구글 TPU와 아마존 Trainium을 사용했으나 엔비디아 GPU를 사용하는 Multi-Cloud, Multi-Chip 전략 추진
 - 구글은 2023년 2월부터 Anthropic이 구글 클라우드(TPU 포함)를 활용해 AI 모델을 학습시키고 서비스를 제공하는 대가로 투자를 지속하여 14%의 지분을 보유
 - 2025년 10월, Anthropic은 최대 백만개의 TPU를 포함한 구글 클라우드 사용 확대 계획을 발표
 - 2026년 4월, Anthropic은 구글, 브로드컴과 차세대 TPU 수 GW 규모의 신규 계약을 체결
 - 아마존은 2023년 9월부터 Anthropic에 AWS 컴퓨팅 자원(Trainium 포함)을 제공하는 대가로 투자를 지속해 10% 중반대의 지분을 보유한 최대 외부 투자자로 부상
 - 2026년 4월, 아마존은 Anthropic에 최대 250억 달러를 투자하고, Anthropic은 향후 10년간 아마존 클라우드 서비스를 1,000억 달러 이상을 이용하기로 합의
 - 2025년 11월에 마이크로소프트·엔비디아·Anthropic은 전략적 파트너십을 발표했으며, 이는 엔비디아와 Anthropic의 첫 본격적인 기술 협력 사례
 - Anthropic은 엔비디아 기술이 적용된 마이크로소프트의 컴퓨팅 자원 300억 달러 규모를 구매하며, 마이크로소프트와 엔비디아는 Anthropic에 각각 최대 50억 달러, 100억 달러 투자를 약속

주요 AI기업의 클라우드와 AI칩 사용 현황

	오픈AI	Anthropic
클라우드	마이크로소프트→오라클, AWS	구글 클라우드, AWS→마이크로소프트
AI칩	엔비디아→AMD, Cerebras, 자체 칩	구글(TPU), 아마존(Trainium)→엔비디아

7) 2027년부터 5년간



- 중동·유럽·아시아 등의 주요국이 소버린 AI를 추진하며 특정 국가와 기업의 의존도를 전략적으로 관리하기 위해 공급망 다변화 등을 추진
- 대부분의 소버린 AI 프로젝트는 미국기업 의존도가 높아 AI Stack중 자국에게 전략적 중요도가 높은 영역에 집중하고, 그 외 부분은 공급망을 관리하는데 집중
 - 미국기업은 반도체, 서버, 클라우드 플랫폼까지 거의 모든 계층에 걸쳐 다수의 소버린 AI 프로젝트에 참여
 - * 소버린 AI 인프라에서 AI반도체 점유율은 엔비디아 92.4%, AMD 4.1%, Cerebras 1.7% 순⁸⁾
 - 국가별로 소버린 AI가 강조하는 분야는 데이터 주권, 모델, 칩, 인프라 등으로 다양하며, EU는 데이터·클라우드 주권, 사우디·UAE는 데이터센터 구축과 아랍어 특화 모델 개발에 집중
- 사우디아라비아와 UAE는 중국과 기술적 연결고리를 정리하며 미국 AI반도체 접근권을 확보했으나, 미국의 AI반도체 수출 통제 정책, 엔비디아 의존도 등을 잠재 리스크로 인식
 - 바이든 행정부는 중국이 중동을 우회하여 미국 AI반도체를 확보한다는 의구심을 갖고 국가별 등급에 따른 AI반도체 수출 통제를 발표해 중동 국가들이 강하게 반발
 - 트럼프 대통령은 2025년 중동 순방을 계기로 중동을 미국 AI 공급망에 편입시킴
 - 미국의 CLOUD Act는 미국계 클라우드 사업자가 관리하는 데이터는 저장 지역과 무관하게 미국 법 집행기관의 접근 대상이 될 수 있어 데이터 주권 이슈가 있음
- 중동 주요국은 미국기업 의존도가 높지만 특정 기업의 의존도를 낮추기 위해 대안을 모색
 - 사우디의 AI기업 Humain은 엔비디아, AMD, 퀄컴, AWS, Groq 등과 협력
 - 사우디의 아람코 디지털은 Groq, Cerebras, 퀄컴, 리벨리온, SambaNova 등과 협력

주요국의 소버린AI 투자액

단위: USD



자료: CNAS.

8) 미국·중국외 55개국 대상 조사(카운터포인트)



II. 주요 기업 및 향후 전망

1. 반도체 기업

1) 엔비디아

엔비디아는 AI Factory 전략하에 GPU 중심 기업에서 AI 구현에 필요한 하드웨어(칩), 소프트웨어, 통신 등을 통합 제공하는 AI 인프라 플랫폼 기업으로 진화

- 엔비디아는 1993년에 설립된 이후 20년 이상 GPU를 개발했으며 2006년에 발표한 CUDA (Compute Unified Device Architecture)를 통해 강력한 진입장벽을 형성
 - CUDA는 그래픽 처리용 GPU를 AI 연산 등 범용 병렬연산(General-Purpose Computing on GPU, GPGPU)에 활용할 수 있도록 해주는 병렬 컴퓨팅 플랫폼이자 프로그래밍 모델
 - CUDA는 GPU에서 수행하는 병렬처리 알고리즘을 C++ 등 산업 표준 언어로 작성할 수 있도록 지원하여 일반 개발자들이 GPU를 이용하기 쉽지 않았던 진입장벽을 해소
 - CUDA Toolkit은 GPU 가속화 애플리케이션 개발에 필요한 GPU 가속 라이브러리* 프로그래밍 언어를 GPU가 이해할 수 있는 명령어로 변환해 주는 컴파일러, 애플리케이션 배포를 위한 런타임 등을 포함
 - * cuDNN(CUDA Deep Neural Network, 딥러닝), cuBLAS(CUDA Basic Linear Algebra Subroutines, 선형대수 연산), NCCL(Nvidia Collective Communication Library, 분산통신) 등
 - CUDA는 엔비디아 GPU에서만 구동되며, CUDA가 업계 표준이 되면서 엔비디아 Lock-in 효과 발생
- 엔비디아는 사업영역을 GPU에서 네트워크, CPU, DPU(Data Processing Unit)* 등으로 확대한데 이어 전력 표준 등을 제시하며 AI 인프라 플랫폼 기업으로 도약
 - * DPU는 네트워크, 스토리지, 보안 관련 작업을 CPU에서 Off-load하여 처리하는 프로세서
- 2020년에 엔비디아는 Mellanox를 인수해 고성능 네트워킹 기술을 내재화하여 데이터 전송 병목을 해소하고, 프로세서·소프트웨어·네트워크에 이르는 Full Stack 제품을 제공
 - Mellanox는 HPC(고성능 컴퓨팅) 클러스터용 네트워크 규격인 InfiniBand⁹⁾와 Ethernet 등의 기술을 보유하며, 엔비디아는 Mellanox의 기술을 기반으로 BlueField DPU를 출시
- 2022년에는 Arm 기반의 자체 데이터센터 CPU인 Grace를 공개했으며, GPU와 CPU를 하나로 결합한 Superchip을 통해 정보를 전송하는 경로를 단축해 저전력을 구현

9) 서버와 서버, 서버와 스토리지 간에 초고속으로 데이터를 송수신할 수 있게 해주는 네트워크 프로토콜



- 2024년에는 데이터센터용 GPU 출시 주기를 2년에서 1년으로 단축

엔비디아의 고성능 GPU 개발 계획

2025	2026	2026 하반기	2027 하반기	2028
Blackwell	Blackwell Ultra	Rubin	Rubin Ultra	Feynman

자료: 엔비디아.

- 2025년말에는 AI반도체기업 Groq을 우회 인수하여 Groq의 LPU 아키텍처 및 소프트웨어 스택에 대한 비독점 라이선스를 확보했으며, 핵심 인력을 엔비디아로 영입
- 2026년 3월에 개최된 GTC 2026에서 엔비디아는 AI Factory 전략하에 7개의 이종 칩을 하나의 통합된 아키텍처로 설계한 Vera Rubin 플랫폼을 공개
 - 2026년 하반기에 출하되는 Vera Rubin Platform은 Vera CPU, Rubin GPU, Groq LPU 등 7개의 이종 칩으로 구성됨
 - * 6개의 이기종 칩으로 구성된 전작 Grace Blackwell Platform에 Groq의 LPU가 추가됨
 - 분산추론 운영체제인 Dynamo는 이기종 하드웨어(GPU, CPU, LPU)를 하나의 논리적 추론 엔진으로 묶어주어 개발자가 코드 수정 없이 모델을 올리면 최적의 자원으로 자동 배분해줌

Vera Rubin Platform에서 7개 칩의 역할

칩	역할
Rubin GPU	연산의 심장-훈련 및 추론의 범용 엔진
Vera CPU	에이전트 오케스트레이션의 두뇌
NVLink6 Switch	6세대 칩간 스위칭 패브릭 (GPU-GPU 간 초고속 데이터 교환)
ConnectX-9 SuperNIC ¹⁾	노드 간 통신 가속기
BlueField-4 DPU ²⁾	보안, 스토리지, 컨텍스트 메모리 처리
Spectrum-6 Ethernet Switch	AI 전용 이더넷 스파인 네트워킹
Groq 3 LPU	Decode 전용 프로세서

주: 1) NIC는 Network Interface Card

2) DPU는 Data Processing Unit(DPU)로 데이터 처리를 담당

자료: 미래에셋증권.

- 2024년에는 Rack 전체를 하나의 컴퓨팅 단위로 설계한 'GB200 NVL72'를 공개하였으며, 2026년에는 하드웨어 확장의 개념을 기존 Rack에서 POD 단위로 재정의
 - Vera Rubin POD는 40개의 랙을 하나의 통합 컴퓨팅 단위로 묶은 개념으로, 최대 60EFLOPS¹⁰⁾의 연산 성능과 총 10PB/s의 대역폭을 구현



- Blackwell부터 액체냉각(Liquid Cooling)을 Rack 표준 사양으로 확정했으며, 교류(AC) 기반 데이터센터 구조를 2027년부터 800V 직류(DC) 중심으로 전환해 전력효율 제고를 추진

엔비디아는 경쟁력을 유지하고 생태계를 강화하기 위해 고객사 다변화, 잠재고객인 AI 기업 육성, NVLink 생태계 개방 등을 추진


- 엔비디아의 매출은 하이퍼스케일러의 비중이 높았으나, 고객사 다변화 노력을 통해 하이퍼스케일러 비중은 60%로 낮아지고, 소버린AI, 엔터프라이즈 등의 비중이 높아짐
- NeoCloud를 육성하기 위해 최신 GPU 우선 배정, 지분투자, 유휴 용량 구매 등을 사용
 - 엔비디아는 Nebius와 CoreWeave의 지분을 각각 9.3%, 6.6%를 보유하며, NeoCloud는 엔비디아 GPU를 구매해 데이터센터를 운영
 - 엔비디아는 CoreWeave가 임차인을 찾지 못할 경우 2032년까지 미판매 용량을 구매하기로 약정
 - 2026년 7월, 엔비디아는 'DSX AI Factory 파트너십'을 통해 클라우드에 Full Stack 하드웨어 인프라를 제공하고 클라우드의 미판매 GPU 용량을 보증 매수하되, 클라우드의 수익을 일부 공유받는 모델을 발표
- AI 도입에 익숙하지 않은 기업들이 엔비디아 하드웨어, 소프트웨어, 플랫폼을 이용해 쉽게 AI 서비스를 구성하도록 지원하며, 자체 오픈소스 AI 모델을 제공
- 엔비디아는 영국, 프랑스, UAE, 인도 등 20여개 국가와 소버린 AI 협력을 진행
- 주요 AI 모델 기업(오픈AI, Anthropic, xAI, Mistral AI 등)에 투자하고 자사 하드웨어 수요 확보, 다양한 AI 모델 공존을 통한 하드웨어 가격협상력 우위 유지 등을 모색
- 엔비디아는 2025년 9월에 오픈AI에 최대 1,000억 달러를 투자하고 오픈AI는 10GW의 엔비디아 GPU 인프라를 구축하는 협력안을 발표했으나, 순환거래로 AI 투자 버블이 커질 가능성이 등이 제기되자 2026년 2월에 300억 달러 지분투자자로 변경
- 2025년 11월, 엔비디아는 Anthropic에 100억 달러를 투자하며, Anthropic은 엔비디아 Grace Blackwell과 Vera Rubin 기반의 최대 1GW의 컴퓨팅 용량을 사용할 계획을 발표
 - Anthropic은 구글과 아마존으로부터 초기 투자를 받아 모델 학습은 구글 TPU를 사용
- 엔비디아는 다수 AI 기업, 클라우드 등과 협력하여 AI 모델의 발전방향을 예상하고 차세대 칩을 설계

10) Exaflops는 컴퓨터가 1초 동안 100경 번의 연산을 수행(10^{18})



- 엔비디아는 NVLink 생태계를 개방하여 타사의 칩(xPU)을 엔비디아 생태계에서 사용할 수 있도록 지원하는 NVLink Fusion을 발표
 - NVLink는 서버 또는 Rack 내의 다수의 GPU를 연결하는 고속 인터커넥트 컴퓨팅 패브릭으로 경쟁 기술 대비 우수한 GPU간 상호 연결 대역폭과 지연시간을 제공
 - 6세대 NVLink는 엔비디아 Rubin 플랫폼에서 GPU당 3.6TB/s의 대역폭을 지원
 - NVLink는 엔비디아 GPU에서만 사용할 수 있으며, AMD, 인텔, 구글 등은 이에 대응하기 위해 개방형 표준 UALink(Ultra Accelerator Link) 컨소시엄을 2024년에 출범시킴
 - 2025년 4월에 발표된 UALink 1.0은 GPU의 상호연결을 PCIe와 이더넷 기술 기반으로 제공
 - 2025년 5월에 발표된 NVLink Fusion은 NVLink 생태계를 부분적으로 개방하여 타사 CPU·AI반도체를 엔비디아의 Rack 규모 인프라에 통합될 수 있도록 함
 - 엔비디아는 인텔, 마벨 등 경쟁 기술 진영에 투자하고 NVLink Fusion에 편입시킴
 - 2025년 9월, 엔비디아는 인텔에 50억 달러 투자를 발표했으며, 양사는 데이터센터·PC용 칩을 공동 개발하며, 생태계 결합을 위해 UALink 멤버인 인텔은 NVLink Fusion에 참여
 - 2026년 3월, 엔비디아는 마벨에 20억 달러를 투자했으며, 마벨은 NVLink Fusion에 참여하면서 엔비디아에게 위협이 되는 ASIC 사업을 상호보완적 구조로 만들
 - NVLink의 CPU 파트너로 인텔, Arm, 후지쯔, Custom Silicon 파트너로 마벨, AWS, 미디어텍, 알칩, GUC, 삼성파운드리 등이 참여
- 엔비디아는 AI반도체 시장 지배력을 유지하기 위해 연간 80억 달러 이상을 R&D에 투자하며, 전체 임직원의 75%가 R&D를 담당

NVLink Fusion 개요



자료: 엔비디아.

주요기업 R&D 투자 현황

단위: 억 달러

		2023	2024	2025
엔비디아	R&D	73	87	129
	매출 대비 R&D 비중	27.2%	14.2%	9.9%
AMD	R&D	59	65	81
	매출 대비 R&D 비중	25.9%	25.0%	23.4%

자료: 연차보고서.



2) AMD

AMD는 사업모델을 칩에서 Rack-scale 솔루션으로 확장하고, 엔비디아의 폐쇄적 생태계에 대응하여 개방형 생태계 구축하면서 엔비디아를 추격

- AMD는 CPU와 GPU 시장에서 각각 인텔과 엔비디아에 이어 2위로 칩 포트폴리오 강화, GPU 출시 주기 단축 및 성능 향상 등을 통해 엔비디아를 추격중
- 칩 포트폴리오를 기업 인수 등을 통해 FPGA, DPU 등으로 확대했으며, 서버·랙 설계 기업 ZT System 인수('25) 등을 통해 시스템 통합 역량을 내재화
 - FPGA 기업 Xilinx, 네트워킹 칩 및 관련 소프트웨어 스타트업 Pensando Systems 등을 인수했으며 2026년 8월에는 AI 추론칩 기업 Taalas 인수 계약을 체결
- AMD는 엔비디아와 동일하게 매년 차세대 칩을 출시할 계획이며, 엔비디아 동급 모델 대비 낮은 수준의 가격을 제시했으나 칩 성능이 향상되면서 가격차를 좁혀가고 있음
 - 2026년에 출시 예정인 MI455X는 연산 Die는 2나노, I/O-Fabric Die는 3나노 공정을 혼용하며, 엔비디아 Rubin GPU는 3나노 공정을 사용해 연산 Die 기준 공정 세대는 AMD가 한 세대 앞섬
 - 2026년에 AI반도체에 HBM4 탑재는 AMD의 MI455X와 엔비디아의 Rubin으로 한정될 전망
 - GPU 평균 판매 가격은 엔비디아 제품이 2024년 19,000달러에서 2026년 33,000달러로, AMD 제품은 동기간 12,000달러에서 29,000달러로 상승할 전망
- ROCm(Radeon Open Compute)은 엔비디아 CUDA 소프트웨어에 대응하기 위해 AMD가 만든 오픈소스 소프트웨어로, 성숙도 측면에서 격차가 있지만 격차를 좁히고 있음
- AMD는 Open Compute Project의 표준에 맞춰 설계된 개방형 AI 레퍼런스 플랫폼 Helios Rack Scale 디자인을 공개하며 사업모델을 칩에서 Rack 단위로 확장
- Open Compute Project는 데이터센터 설계를 표준화·개방화하기 위해 2011년에 Meta 주도로 설립된 비영리 오픈소스 하드웨어 컨소시엄으로, 서버·랙·네트워킹 장비 등의 설계 규격을 공개하여 특정 벤더에 종속되지 않는 상호운용 가능한 인프라 구축을 지향
- 2025년에 Meta는 신규 개방형 랙 표준인 'Open Rack Wide(ORW)'¹¹⁾를 제안하였으며, AMD는 이를 기반으로 자사 최초의 랙스케일 플랫폼 'Helios'를 구현
- 동 플랫폼은 Scale-up(랙 내부 연결)은 UALink, Scale-out(랙 간 연결)은 Ultra Ethernet Consortium을 지원
- 2025년 AMD의 데이터센터 부문 매출(CPU, GPU 등)은 166억 달러로 전년 대비 32% 성장했으며, 고객사는 메타, 오픈AI, 오라클 등
- Helios는 2026년 하반기에 출하될 계획으로 마이크로소프트, 오픈AI 등을 고객사로 확보

11) GW급 데이터센터 수요에 맞춘 Rack 규격



AMD는 오픈AI, Meta, Anthropic과 지분투자 연계형 장기 공급계약을 체결

- 2025년 10월, AMD와 오픈AI는 6GW의 GPU 구매를 위한 전략적 파트너십을 체결
 - 오픈AI에게 구매 물량 조건 충족시 AMD 지분 10%에 해당하는 신주(1.6억주)를 주당 0.01달러에 매입할 수 있는 신주인수권을 부여
- 2026년 2월, AMD는 Meta와 5년간 최대 6GW 규모의 칩 공급 계약을 체결했으며, 오픈AI 계약과 동일한 조건의 신주인수권을 부여
- 2026년 7월에 Anthropic은 2027년 상반기부터 AMD의 MI450을 최대 2GW 규모로 도입할 계획을 발표했으며, AMD는 Anthropic에 최대 50억 달러를 투자할 예정
 - 양사는 AMD의 GPU에서 Claude 워크로드 최적화, ROCm 개발 가속화 등도 협력할 계획

3) 인텔

인텔은 AI반도체 사업이 부진하지만 차세대 칩 개발, 추론시장 공략을 위해 이기종 분산 추론 제공 등을 통해 경쟁력 제고를 추진

- 인텔은 세계 1위 CPU 기업으로 이스라엘 AI반도체 스타트업 하바나랩스를 인수하고 데이터센터용 AI반도체 시장을 공략했으나 2025년 시장점유율은 1% 미만
 - 2016년에 AI반도체 스타트업 Nervana를 인수했으나 Nervana 기반 제품은 실패했으며, 이후 2019년에 AI반도체 기업 하바나랩스를 인수
 - 하바나랩스는 2024년에 3세대 AI반도체 Gaudi3를 출시했으나, 소프트웨어 문제 등으로 판매 부진을 겪음
 - 인텔은 엔비디아의 CUDA에 대응하기 위해 CPU, GPU 등 다양한 기업의 AI반도체를 지원하는 개방형 표준기반 이기종 프로그래밍 모델을 개발했으나 소프트웨어 호환성 문제 등이 발생
 - Gaudi3의 후속 모델 Falcon Shores는 업계 피드백을 받은 후 내부 Test 칩으로 활용하고, 2026년말에 추론용 GPU인 Crescent Island를 출시할 계획
 - Crescent Island는 LPDDR5X를 탑재하여 비용 효율성을 제공하며, 공랭식 서버에서 사용 가능
 - 2027년에 차세대 플래그십 GPU인 Jaguar Shores를 출시할 전망
- 인텔은 삼바노바, 폭스콘과 Rack 스케일 AI 추론 인프라 공동 구축을 추진
 - 인텔은 삼바노바 인수를 추진했으나 인수가 무산되자 전략적 협력 관계로 선회
 - * 인텔의 삼바노바 지분은 2025년 6.8%에서 2026년 2월 8.2%로 확대됨
 - 인텔의 Xeon CPU와 삼바노바의 RDU(Reconfigurable Dataflow Units)를 결합하고, 폭스콘은 Rack 레벨 시스템 통합 지식 등을 제공



4) 퀄컴

퀄컴은 모바일 중심의 사업을 영위했으나 데이터센터 AI 추론·Agentic AI 시장을 타겟으로 데이터센터용 CPU, 추론용 칩, ASIC 개발을 추진

- 퀄컴은 추론용 칩 AI200을 2026년, AI250을 2027년에 출시할 계획이며, 사우디아라비아 AI 스타트업 Humain*은 2026년부터 AI200·250 기반 200MW급 랙 솔루션을 도입할 계획
 - * 사우디아라비아 국부펀드 소유 국영 AI기업으로 칩셋 포트폴리오는 엔비디아, AMD, 퀄컴 중심
- 2025년 11월, 퀄컴은 사우디아라비아의 수도 리야드에 '퀄컴 AI 엔지니어링센터'를 설립하고, 기업들이 퀄컴의 인프라로 AI 모델을 Migration 할 수 있도록 기술 지원 등을 담당
- 2026년 6월, 퀄컴은 Agentic AI를 위한 CPU, AI반도체, 메모리, 소프트웨어를 하나로 묶은 통합 플랫폼 Dragonfly 브랜드를 발표
 - Agentic AI에 초점을 맞추어 신규 서버용 CPU Dragonfly 1000, 3세대 AI 추론용 반도체 Dragonfly AI300을 공개했으며, 2028년에 양산될 C1000은 Meta를 고객사로 확보
 - 퀄컴은 HBM 대비 저전력을 소비하는 LPDDR 기반의 HBC(High-Bandwidth Compute)를 공개했으며, HBC는 A250에 처음으로 적용될 계획
 - HBC는 AI반도체 위에 대용량의 LPDDR 패키지를 얹은 뒤 실리콘관통전극(Through Silicon Via, TSV)으로 수직 연결하는 방식
 - 퀄컴은 AI 소프트웨어 스타트업 Modular* 인수를 통해 엔비디아 CUDA에 대응할 계획
 - * 여러 AI반도체에서 코드 수정 없이 AI 모델을 구동할 수 있도록 지원하는 소프트웨어를 개발
- 퀄컴은 데이터센터 부문 매출 목표를 2027 회계연도('26.10~'27.9)에 50억 달러, 2029 회계연도('28.10~'29.9)에 150억 달러로 수립



2. 하이퍼스케일러

1) 구글

구글이 출시한 AI ASIC TPU는 AI ASIC 중 가장 성공한 사례로, 구글은 TPU를 자사 클라우드를 통해 외부에 임대해왔으나 최근 외부 판매로 사업 전략을 변경

- 구글의 자체 AI반도체 TPU(Tensor Processing Unit)는 구글의 AI 엔진 TensorFlow에 최적화되어 있으며 2026년에 8세대 TPU를 공개
- 구글은 TPU를 자사 검색엔진, 유튜브 알고리즘, 구글 클라우드 등에 사용중이며, 2026년에 구글로 인도되는 AI 서버 중 TPU의 비중은 약 78%로 예상
 - 구글은 세계 3위의 클라우드로 2018년부터 구글 클라우드 플랫폼(GCP)를 통해 외부 기업 등에 TPU를 임대
 - 구글은 브로드컴과 협력하여 TPU를 설계하며, 구글은 GPU 기반 서버보다 ASIC 기반 서버를 더 많이 채택하는 유일한 클라우드¹²⁾
- 구글은 7세대 TPU까지는 학습과 추론 겸용의 칩을 출시했으나 8세대 TPU는 학습용 TPU 8t와 추론용 TPU 8i로 물리적 기능을 분리

구글 TPU 개발 현황

칩	출시 시기	주요 특징
TPU v1	2015	추론 전용
TPU v2	2017	신경망 학습 기능 추가
TPU v3	2018	전작 대비 연산능력이 2배 이상 향상. 액체 냉각 도입
TPU v4	2021	전작 대비 성능이 2배 이상 향상
TPU v5e	2023	TPU 라인업 이원화 - v5e(고효율), v5p(고성능)
TPU v6e(Trillium)	2024	전작 대비 에너지 효율 67% 개선
TPU v7(Ironwood)	2025	초대형 AI 모델에의 추론과 학습을 위해 설계
TPU 8t, TPU 8i	2026 하반기	학습용 칩과 추론용 칩을 분리

자료: IITP, Medium.

12) Trendforce, 'Combined CapEx of Top Eight CSPs to Exceed \$710 Billion in 2026: Google Leads ASIC Deployment with TPUs', 2026.2.25



- 구글은 최근 TPU의 외부 판매를 결정했으며, TPU 출하량은 2025년 450만개에서 2027년 790만개로 증가할 전망
- Anthropic은 2025년 10월에 백만개의 TPU를 포함한 구글 클라우드 사용 확대 계획을, 2026년에 2027년부터 5년간 3.5GW의 TPU 임대 계획을 발표
 - 2025년 10월, Anthropic은 최대 100만개의 TPU를 포함한 구글 클라우드 사용 확대 계획을 발표(1GW 규모)¹³⁾
- Meta는 엔비디아 의존도를 낮추기 위해 AI 모델 개발용 TPU를 임대하는 계약을 체결했으며 2027년부터 자사 데이터센터에 TPU를 도입하는 방안을 논의중¹⁴⁾
- 2024년에 자체 개발한 ARM 아키텍처 기반의 서버용 CPU Axion를 공개
- 서버용 CPU Graviton은 ARM 아키텍처를 채용하여 인텔, AMD가 사용하는 기존 X86 아키텍처 기반 CPU 대비 저전력을 사용

2) 아마존

AWS(Amazon Web Service)는 세계 1위 클라우드로 2018년부터 자체 칩 개발을 추진해 ARM 기반의 CPU Graviton, 학습용 칩 Trainium, 추론용 칩 Inferentia를 개발

- 아마존은 ARM 아키텍처 기반의 CPU Graviton, 학습용 칩 Trainium, 추론용 칩 Inferentia 등을 발표했으나 AWS는 아직 GPU 사용 비중이 높음
- 5세대 Graviton은 Agentic AI에 최적화되어 있으며, AWS의 서버 CPU중 자체 칩 비중은 2022년에 3%였으나 2026년에는 신규 도입하는 CPU의 50% 이상은 자체 칩을 탑재할 전망
- 아마존은 이스라엘 팸리스 Annapurna Labs를 인수('15)하고 자체 AI반도체를 개발해 2세대 Inferentia 칩과 3세대 Trainium 칩을 출시
- 2027년 출시 예정인 4세대 Trainium 칩은 엔비디아의 초고속 연결 기술인 NVLink Fusion을 통합하여 아마존의 AI 인프라 배포 속도를 단축할 계획
 - NVLink Fusion은 하이퍼스케일러가 자사의 Custom ASIC과 CPU를 엔비디아 AI 인프라 플랫폼에 배치할 수 있도록 지원하는 기술
- 아마존이 자체 칩을 출시하지만 2026년 AI 서버에서 GPU 비중은 약 60%로 전망

13) Anthropic, 'Expanding our use of Google Cloud TPUs and Services', 2025.10.23

14) 한국경제, '메타, AI 학습에 TPU도 쓴다...자체 칩 전략은 폐기', 2026.2.27



- 아마존은 자체 칩을 AWS 고객에게 임대해왔으나 외부 데이터센터에 칩 판매를 검토
- 아마존은 Anthropic, 오픈AI에 투자하는 대가로 AWS 사용 계약을 추진하여, 아마존은 Anthropic에 80억 달러를 투자했으며 Anthropic은 AWS를 이용중
- 2026년 4월, Anthropic은 2036년까지 10년간 5GW의 Trainium 칩을 확보할 계획을 발표했으며, 아마존은 Anthropic에 50억 달러를 투자하고 최대 200억 달러를 추가 투자할 예정
 - 아마존과 Anthropic은 약 50만 개의 Trainium2 칩을 탑재한 AI 컴퓨팅 클러스터 Project Rainier를 출범시켰으며(25), Anthropic은 이 클러스터를 활용해 Claude 모델을 학습 및 배포하고 Annapurna Labs와 협력해 차세대 Trainium 칩 개발에 협력
- 2026년 2월, 오픈AI는 AWS 인프라를 통해 약 2GW 규모의 Trainium 칩을 활용할 계획을 발표했으며, 아마존은 오픈AI에 500억 달러를 투자할 계획
- 아마존은 자체 칩 사업부의 2026년 연환산 매출액은 250억 달러 이상이며¹⁵⁾, 외부 판매를 본격화하면 연 매출이 500억 달러 이상이 될 것으로 전망
- 아마존의 자체 칩 판매는 유럽 등의 소버린 AI 수요가 Target인 것으로 추정됨

3) Meta

Meta는 AI 학습은 타사 칩, 추론은 자체 칩(MTIA) 사용을 통해 데이터센터 확장 효율성 제고를 추진

- Meta는 2023년 1세대 MTIA(Meta Training & Inference Accelerator), 2024년 2세대 칩을 공개했으며, 향후 2년내에 4개의 칩을 6개월 주기로 출시할 계획
- Meta는 자체 데이터센터에서 MTIA 300을 사용중이며, MTIA 400은 테스트를 완료하고 데이터센터 배치 단계에 있으며, MTIA 450과 500은 2027년에 출시할 계획
- MTIA 300은 SNS(Social Network Service)의 콘텐츠 추천 및 순위 서비스에 특화된 칩, MTIA 400은 범용, MTIA 450과 500은 생성형 AI 추론에 특화된 칩
- Meta는 MTIA 400을 주요 상용 칩과 경쟁할 만한 성능을 갖춘 최초의 자체 칩으로 평가
- Meta는 자체 칩 개발을 위해 브로드컴과 협력중이며, 2025년 미국 반도체 스타트업 Rivos를 인수
- 2026년 4월, Meta는 브로드컴과 2029년까지 1GW 규모의 AI 칩 공급계약을 체결했으며, 브로드컴은 Meta의 반도체 설계, 첨단 패키징, 네트워킹을 지원
- Rivos는 RISC-V 오픈소스 아키텍처를 기반으로 GPU와 AI반도체를 설계하는 스타트업

15) 2026년 아마존 실적발표



Meta의 AI반도체 로드맵

	MTIA 300	MTIA 400	MTIA 450	MTIA 500
출시시기	사용중	테스트 완료	2027년초	2027년 하반기
타겟 워크로드	추천 및 순위 기능 학습	범용	생성형AI 추론	생성형AI 추론
모듈 TDP	800W	1,200W	1,400W	1,700W
HBM 대역폭	6.1 TB/s	9.2 TB/s	18.4 TB/s	27.6 TB/s
HBM 용량	216 GB	288 GB	288 GB	384~512 GB

자료: Meta, 트렌드포스.

- Meta는 AI 컴퓨팅 용량 확보와 연산 자원 다각화를 위해 엔비디아·AMD의 칩 사용, 구글 클라우드 TPU 임대 등을 병행하고 있음
 - 2026년 2월, AMD는 Meta와 6GW 규모의 GPU 공급계약을 체결했으며, AMD는 협력 강화를 위해 Meta에 AMD 보통주에 대한 GPU 구매량 기반 신주인수권을 발행
 - Meta는 AI모델 개발을 위해 구글과 다년간 TPU를 임대하며, 2027년에는 TPU 직접 구매로 전환하는 협상을 진행중
 - 2026년 4월, Meta는 AI 선도기업과의 컴퓨팅 격차를 해소하기 위해 네오클라우드 CoreWeave와 210억 달러의 장기 컴퓨팅 공급계약('27~'32.12)을 체결
 - 엔비디아 Vera Rubin 플랫폼 구축 등이 포함됨




3. 스타트업

1) Cerebras Systems

Cerebras Systems는 세계 최대 크기의 AI칩을 별도로 판매하지 않고 시스템 또는 클라우드로 판매

- 2015년에 AMD 출신 엔지니어가 설립한 미국 AI반도체 스타트업으로 웨이퍼 전체를 단일 칩으로 만드는 Wafer-Scale Engine(WSE)을 출시
- 일반적인 반도체는 웨이퍼에 회로를 형성한 후 개별 Die 단위로 절단·패키징하며, 주요 AI반도체는 개별 칩을 인터커넥트 기술로 병렬 연결하여 연산성을 확장
- WSE는 웨이퍼 1장을 단일 칩으로 사용하여 칩 내부 연산 요소간 별도의 외부 연결이 불필요하여 신호 전달 속도가 빠르고 저전력이 장점
- WSE는 세계 최대 크기의 AI 칩으로 전력 소비가 23kW로 커서 초기부터 냉각, 전력, 네트워킹 등을 갖춘 CS(Cerebras System)으로 판매
- 2019년에 1세대 WSE-1, 2021년 2세대 WSE-2, 2024년 3세대 WSE-3를 공개했으며, WSE-3은 이론상 엔비디아 H100 62개에 해당하는 성능을 제공
- WSE-3은 90만개의 컴퓨팅 코어와 44GB의 On-Chip S램을 탑재하여 멀티 GPU 시스템에서 발생하는 데이터 지연 및 대역폭 병목 문제를 해결해줌

Cerebras의 Wafer Scale Engine 3 크기




자료: Cerebras.

초당 토큰 생성량

Output Speed: gpt-oss-120b (high)

Output speed: output tokens per second · 10,000 input tokens



자료: Artificial Analysis.



타겟 시장은 초기에는 WSE의 기술 검증을 위한 소수 연구기관을 대상으로 한 AI 학습 시장에 집중되었으나, 이후 AI기업·소버린 AI 프로젝트와 추론 시장으로 이동

- CS-1(WSE-1 탑재)은 국립연구소(미국 아르곤 국립연구소 등)와 제약사(GSK 등)를 고객으로 확보하고 제품을 검증
- CS-2(WSE-2 탑재)은 UAE의 AI-클라우드기업 G42와 협력하며 클라우드 서비스 사업을 시작
 - 2021년에 G42와 중동 AI 컴퓨팅 인프라를 구축하기 위한 파트너십을 체결
 - 2023년에 G42와 9개의 슈퍼컴퓨터 구축사업 Condor Galaxy 프로젝트를 발표했으며, G42는 소유권을 보유하고 Cerebras가 슈퍼컴퓨터의 구축·관리·운영을 담당
 - 초기 3개의 프로젝트가 미국내에 구축되었으며*, 초기 2개의 프로젝트는 AI 모델 학습에 사용
 - * G42는 중국기업과 연계 의혹으로 미국의 감시를 받았으며, 미국의 첨단 AI반도체 수출 규제 회피 및 신뢰 회복을 위해 미국에 데이터센터를 설립한 것으로 추정됨
 - G42가 사용하지 않는 Condor Galaxy의 잉여 용량은 Cerebras Cloud를 통해 판매
- 2024년에 출시된 Cerebras Inference Cloud는 사전 학습된 AI 모델(오픈소스 모델 중심)을 실행하고 그 결과를 API(Application Programming Interface) 형태로 제공
 - 미국 오클라호마 시티와 캐나다 몬트리올 데이터센터는 코로케이션¹⁶⁾ 사업자와 협력
- CS-3(WSE-3 탑재)부터는 소버린 AI를 지원하는 Cerebras for Nation을 발표하고 미국, UAE, 인도와 협력
 - 미국의 Genesis Mission은 연방 정부의 과학 데이터와 국립연구소의 컴퓨팅 인프라를 통합해 과학 연구 및 산업의 혁신 속도를 제고하려는 프로젝트로 Cerebras도 참여
 - 2026년 2월에 G42, UAE의 국립 AI 전문 대학(MBZUAI), 인도 전자정보기술부 산하 C-DAC (Centre for Development of Advanced Computing)과 Condor Galaxy India를 발표
- 2026년 7월, Cerebras는 AMD와 AMD의 Helios 랙스케일 솔루션과 Cerebras 칩을 결합한 이기종 분산형 추론 솔루션 제공을 위한 기술 협력을 발표
- 세레브라스는 자사 데이터센터에 AMD Helio를 도입할 계획

Condor Galaxy의 미국 프로젝트



자료: Cerebras.

16) 기업이 소유한 서버 등 IT 장비를 제3자가 운영하는 데이터센터에 설치하고 운영하는 방식으로, 데이터센터 운영 기업은 공간, 전력, 냉각 등을 제공



소수의 대형 고객 집중도가 높았으나 오픈AI-AWS와 협력을 통해 고객사를 다변화했으며, 사업지역도 북미에서 유럽 등으로 다변화를 추진

- 2025년 매출의 86%가 UAE 정부·왕가 계열의 단일 지정학적 공급망에 묶여 있음
 - 2024년에는 총매출의 85%를 UAE의 G42가 담당하며, G42는 투자자이자 고객
 - 2025년에는 총매출의 24%는 G42와 62%는 G42의 특수 관계인 UAE의 국립 AI 전문 대학(MBZUAI)으로 명의가 분산됨
- 2026년 1월에 발표된 오픈AI와 계약은 AI 인프라를 2028년까지 750MW의 구축하고 향후 2GW로 확장할 수 있으며, 다년간 계약은 200억 달러 규모
 - OpenAI는 Cerebras에 10억 달러의 운전자금을 대출해주고¹⁷⁾ 주식 3,300만주를 거의 무상에 매입할 수 있는 워런트¹⁸⁾를 받아 향후 주주가 될 수 있음(지분율 10% 규모)
 - 오픈AI는 Cerebras 칩 맞춤형 모델 'GPT-5.3-Codex-Spark'를 출시
- 2026년 3월, Cerebras는 AWS와 협력해 분산 추론에서 Prefill은 아마존의 Trainium3, Decode는 세레브라스의 CS-3이 담당하는 다년간의 파트너십을 발표
- 2026년 7월, Cerebras는 2027년 말까지 유럽에 200MW의 컴퓨팅 용량 배치 계획을 발표
 - * 일부 용량은 OpenAI가 사용 예정

Cerebras의 매출은 2022년 25백만 달러에서 2025년 5억 달러로 약 20배 성장했으며, 2025년 매출 비중은 하드웨어 70%, 클라우드·기타 서비스가 30%

- 2026년 1분기 매출은 전년동기 대비 94% 증가한 1.9억 달러이며, 하드웨어 매출 비중은 57%, 클라우드·기타 서비스 매출은 43%로 클라우드가 성장을 견인
- 수주 잔고(Remaining Performance Obligation)는 246억 달러*, 시가총액('26.6.24)은 400억 달러

* 오픈AI와 계약규모가 200억 달러 이상

Cerebras의 매출

단위: 백만 달러

	2022	2023	2024	2025
매출	25	79	290	510
영업손실	179	134	101	146

자료: Cerebras.

17) 이율 연 6%, 대출 만기시 현금, 컴퓨팅 능력 또는 하드웨어로 상환 가능

18) 주당 행사가격은 \$0.00001




2) Sambanova Systems

삼바노바는 추론 시장을 타겟으로 칩을 단품으로 판매하지 않고, Rack을 제작하고 배송하는 사업모델을 보유

- 2017년에 스탠퍼드대 교수진이 창업한 미국 AI반도체 스타트업으로 FPGA처럼 재구성이 가능한 RDU(Reconfigurable Dataflow Unit)를 개발한 유니콘 기업
 - 삼바노바는 AI의 연산 지연, 비용 상승의 원인이 데이터 이동 방식에 있다고 판단하여, 데이터 이동 중심으로 설계된 RDU(Reconfigurable Dataflow Unit)를 개발
 - RDU는 명령어 중심 처리구조를 보유한 GPU와 달리 AI 모델의 연산 그래프에 맞춰 칩 내부의 타일형 연산 유닛과 메모리 유닛을 재구성하여 데이터 이동 경로를 최소화
 - 주요 투자자는 소프트뱅크, 인텔, 블랙록, 싱가포르 국부펀드 테마섹, 삼성, 구글 등
 - 2023년에 4세대 칩 SN40을 출시했으며, 2026년 하반기에 Agentic AI 워크로드에 강점을 보유한 5세대 칩 SN50을 출시할 계획
 - RDU 기술은 학습 중심의 SN10에서 출발해 SN30에서 학습·추론을 단일 시스템으로 통합
 - SN40은 HBM 도입으로 3단계 메모리 계층 구조(S램, HBM, D램)를 통해 대형 모델에 대응했으며, SN50은 초대형 AI 모델과 Agentic AI에 최적화된 구조로 설계됨
 - 삼바노바는 AI칩부터 소프트웨어, 모델까지 제공하는 Full-stack AI 인프라 기업으로, 하드웨어·네트워킹·소프트웨어를 통합한 SambaRack* 단위로 시스템을 공급
- * SambaRacks은 기존 공랭식 시스템과 호환되는 방식의 AI 서버
- 제품 라인업은 오픈소스 모델을 제공하는 클라우드 추론 서비스 SambaCloud, 보안을 중시하는 기업·정부가 전용 인프라를 직접 구매·운용할 수 있는 SambaStack, 고객사 데이터센터내에 위치하되 삼바노바가 위탁 운영하는 SambaManaged로 구성됨

삼바노바의 제품 포트폴리오



자료: 삼바노바.



타겟 시장은 소버린 AI, 고성능 추론 서비스를 제공하려는 클라우드, 안보를 중시하는 기업 등이며, 소프트뱅크, JP모건체이스, 사우디 아람코 등을 고객으로 확보

- 호주, 독일, 영국, 프랑스, 일본의 현지 기업과 협력하여 소버린 클라우드를 구축
- EU는 유럽 클라우드 시장의 73%를 차지하는 미국 하이퍼스케일러에 대한 의존도를 2030년까지 50% 이하로 낮추기 위해 유럽기업이 주도하는 소버린 클라우드 육성을 추진
- 프랑스에서는 OVH클라우드, 일본에서는 소프트뱅크와 협력하며, 이들의 데이터센터에 삼바노바 Rack을 배치, 호스팅하는 방식으로 사업을 영위
- 2026년 2월, 삼바노바와 인텔은 이기종 AI 추론 솔루션 제공을 위한 협력을 발표했으며, 첫 고객사로 소프트뱅크를 확보
- 삼바노바는 동일 수준의 고성능 추론 성능을 구현하는데 '인텔+삼바노바' 진영이 '엔비디아+Groq' 대비 훨씬 적은 수의 칩과 전력소모량으로 구현 가능하다고 평가
- 2026년 7월에 JP모건 체이스는 삼바노바를 온프레미스 AI 추론 인프라 파트너로 선택

프리미엄 추론 시장 경쟁 구도

		인텔+삼바노바	엔비디아+Groq	Cerebras
추론 시스템	Prefill	GPU 또는 RDU	엔비디아 Rubin GPU	GPU
	Decode	삼바노바 SN50	엔비디아 Rubin GPU, Groq 3 LPU	Cerebras CS-3
	CPU	인텔 Xeon 6	엔비디아 Vera	RISC-V 기반
고성능 추론 ^{주)} 에 필요한 Decode 칩		256개 (삼바노바 SN50)	2,000개 이상 (Groq 3 LPU)	불가능 (Cerebras CS-3)
데이터센터 적합성		기존 데이터센터에 연결 가능 - 랙당 30kW만 필요	신규 액체 냉각 데이터센터 시설 필요 - 1MW 이상	해당 없음

주: 프리미엄 추론은 수조개의 파라미터 모델에서 초당 약 200개 이상의 토큰을 디코딩
자료: 삼바노바.

삼바노바의 기업가치는 2021년 51억 달러에서 2026년 7월 110억 달러로 상승

- 삼바노바의 기업가치는 2021년 4월 시리즈D 당시 51억 달러로 평가되었으나, 2025년 말 인텔 인수 협상 결렬 당시 약 16억 달러로 하락
- 2025년 4월, 삼바노바는 사업전략을 AI 학습에서 AI 추론 및 클라우드 서비스로 재편했으며, 매출 부진 등으로 약 500명의 인력중 약 15%를 감원
- 2026년 2월 시리즈E에서 약 22억 달러로 회복했다가 2026년 7월 시리즈F에서 인텔과 파트너십, JP모건체이스와 협력 등으로 110억 달러로 급등



3) Groq

Groq는 대형언어모델(LLM)의 실행 속도를 높이 LPU(Language Processing Unit)를 개발했으며, 칩을 판매하지 않고 AI 추론 클라우드 구축에 집중

- 2016년 구글 TPU 개발자가 설립한 미국 AI반도체 기업으로 LPU는 HBM 대신 On-chip S램을 사용해 저지연을 구현
 - 2019년에 1세대 LPU를 출시했으며, 2세대 LPU는 기술 이슈, AI 트렌드 변화 등으로 출시되지 못하고 2026년에 LPU3 출시 예정
 - 주요 투자자는 삼성, Cisco, 블랙록 등이며, LPU3는 삼성 파운드리가 제조
- Groq은 2024년부터 칩 직접 판매를 중단하고, LPU 기반의 GroqCloud를 통해 서비스를 제공하고, 해외 파트너와 협력해 데이터센터에 기술을 제공하는 방향으로 사업모델을 전환
 - 창업자 Jonathan Ross는 스타트업이 칩을 직접 판매하는 것은 수익성이 있으려면 최소 구매 수량이 많아야 하며, 비용 부담이 높아 사실상 어렵다고 판단하고 사업모델을 전환
 - Groq은 북미, 유럽, 중동, 아시아 태평양 지역에 13개의 데이터센터를 운영중이며, 데이터센터를 직접 건설·보유하지 않는 Asset-Light 전략을 채택
 - 북미·유럽·아시아태평양에서는 Colocation 사업자의 시설을 임차해 LPU Rack을 배치
 - 북미에서는 에퀴닉스, DataBank, Bell Canada와 협력하며, 에퀴닉스와 협력해 핀란드('25.7), 호주('25.11), 영국('26.2)으로 사업을 확대
 - 사우디의 대규모 사업은 현지 파트너가 인프라 비용·부지를 제공하고 Groq이 칩·기술을 공급
 - 2024년, 사우디 아람코의 자회사 아람코 디지털은 AI 추론 데이터센터를 구축하기 위해 Groq의 LPU 19,000개를 우선 도입하고, 향후 최대 20만개까지 확대할 계획을 발표
 - 2025년 2월에 발표된 사우디의 AI기업 Humain 협력도 아람코 디지털 협력 방식과 동일
- Groq은 2025년말에 엔비디아에 우회 인수되었지만 독립법인으로 클라우드 사업을 영위
 - Groq의 2025년 매출 목표는 5억 달러이나 2025년 12월 엔비디아와 라이선스 계약 시점에 매출이 약 1억 달러로 부진하여¹⁹⁾ 엔비디아와 계약을 수용한 것으로 추정됨
 - 매출 부진은 사우디의 데이터센터 용량 부족과 2025년 5월 트럼프 대통령의 중동 순방을 계기로 엔비디아-AMD의 칩의 사우디 반입이 본격화되면서 경쟁이 심화된 것으로 추정됨
 - Groq의 직원 약 90%가 엔비디아로 이직했으며 Groq은 신규 경영진 영입과 대규모 자본 조달을 통해 데이터센터 규모를 2027년까지 200MW 규모로 확대할 계획

19) Fortune, 'Sometimes You Don't Want A GPU: Groq Cofounder Explains Whirlwind Deal With Nvidia', 2026.3.18



4) Graphcore

Graphcore는 영국을 대표하는 AI반도체 스타트업으로 한때 엔비디아의 대항마로 부상했으나 대형 고객사 이탈 등으로 소프트뱅크에 인수됨

- 2016년에 엔비디아 출신 개발자가 설립한 기업으로 IPU(Intelligent Processing Unit, 지능형처리장치)를 설계하며 마이크로소프트, 삼성전자 등의 투자를 받음
- IPU는 벡터 연산을 지원하는 GPU와 달리 그래프 연산²⁰⁾을 지원하며 칩 안에 데이터를 저장할 수 있는 메모리를 넣어 연산 지연을 해소하면서 유니콘 기업으로 부상
- 주요 투자자는 마이크로소프트, BMW 등이며, 주요 구매자는 마이크로소프트, Cirrascale, NHN클라우드 등
- Graphcore는 마이크로소프트의 구매 중단, 미국의 대중국 반도체 수출 규제('23), AI 반도체 기술 경쟁 심화 등으로 매출이 급감하면서 매각 추진
- IPU는 GPU와 달리 용도가 한정적이고 엔비디아 중심의 소프트웨어 생태계와 호환되지 않아 마이크로소프트는 칩 도입 1년만에 구매를 중단
- 비영리·공공 프로젝트에 집중하면서, 민간 기업들이 참고할 만한 상용화 성공 사례가 부족하여 영국 정부 주도의 슈퍼컴퓨터 프로젝트에서도 외면받음
- 2022년 매출은 전년 대비 46% 감소한 2.7백만달러를 기록했으며 중국이 주력시장(매출비중 20~25%)이었으나 2023년에는 미국의 규제로 중국에서 철수
- Graphcore는 2024년에 소프트뱅크에 인수된 후 소프트뱅크의 자금 지원과 인프라를 기반으로 사업 확장을 추진

20) 벡터 연산은 3D 그래픽스 등을 지원, 그래프 연산은 소셜네트워크에서 인물과의 관계망을 만들거나 화합물, 단백질 구조 등 다양한 종류의 데이터 처리를 지원(KIPOST)




4. 향후 전망

엔비디아는 기술, 생태계, 자본 등을 기반으로 지배적 지위를 유지하나 AI 추론 워크로드 다변화와 수요기업의 추론 경제성 확보 노력으로 후발주자의 시장 진입 기회도 확대될 전망

- 주요 AI반도체의 경쟁력을 추론 비용 곡선을 통해 분석한 결과를 살펴보면, 엔비디아 GPU가 가장 우수하며, 구글 TPU는 엔비디아 GPU와 격차를 좁히고 있음
- 엔비디아는 매년 GPU 신제품을 출시하며, 독보적인 CUDA 생태계, Rack 시스템 최적화 등을 통해 가장 경쟁력 있는 추론 비용을 달성해 엔비디아의 추론칩 시장점유율은 2026년 1분기에 74%를 기록
- 구글 TPU는 메모리(HBM), 네트워킹 등에 집중하면서 엔비디아의 대안으로 부상
 - 설계 파트너인 브로드컴의 세계 최고 수준의 이더넷 네트워킹, SerDes(Serializer-Deserializer, 직렬-병렬 변환기) 기술 등이 TPU의 성능 향상과 비용 절감에 결정적인 기여를 함
 - * 엔비디아의 InfiniBand는 고가이지만, 브로드컴의 이더넷 스위치는 가격이 낮으며, SerDes는 고속 데이터 전송을 위해 데이터의 직렬-병렬 전환을 수행해 TPU 클러스터의 확장성을 높임
 - TPUv7의 토큰당 비용은 구글 TPUv6의 토큰당 비용 대비 약 70% 하락하면서 백만 토큰당 비용은 엔비디아 GB200 NVL72와 유사한 수준에 도달
- AMD의 GPU와 아마존의 Trainium은 선도그룹 대비 추론비용 효율성이 낮지만, AMD의 Helios 랙과 아마존의 차세대 칩이 출시되면 선도그룹과의 격차를 줄일 전망
 - AMD는 Helios 랙 솔루션이 엔비디아 Vera Rubin NVL72급 성능을 제공한다고 주장

AI반도체별 백만 토큰당 추론비용 추이




자료: 골드만삭스.



- 엔비디아는 추론 칩 시장에서도 견고한 지배력을 보유하나, 추론 워크로드 다변화, 멀티 벤더 전략 등으로 엔비디아와 기업들의 성장이 가속화될 전망
- 엔비디아는 저지연을 확보하려면 처리량을 희생해야한다는 기존의 Trade-off를 차세대 GPU의 성능 향상, 이기종 분산 추론을 통해 동일한 응답성 수준에서 달성 가능한 처리량의 상한선을 크게 확장시킴
 - Vera Rubin 플랫폼에 Groq의 LPX(다수의 LPU를 서버 랙 형태로 통합)를 도입해 사용자의 고응답성 구간(400 TPS per User)에서 전작 Blackwell 대비 최대 35배 높은 처리량을 달성
- 추론 워크로드는 추천 시스템, 코드 생성, 멀티모달 처리 등으로 다변화되면서 고가의 범용 GPU를 사용하기보다 워크로드별 특성에 최적화된 칩 채택이 확대될 전망
- 엔비디아의 최신 칩은 전력소비 증가, 기존 공랭식 대비 투자비 부담이 큰 수랭식 액체냉각 방식으로의 전환 등이 엔비디아 칩 도입을 제약할 요인이 될 전망

엔비디아의 이기종 분산 추론 도입 효과



주: 추론 성능을 처리량(TPS(Token per Second) per MW)과 응답성(사용자당 초당 토큰수)로 비교
자료: 엔비디아.


- 데이터센터용 AI반도체 시장에서 GPU外 반도체의 비중은 2025년 18%에서 2030년 41%로 확대될 전망
 - GPU 시장은 2025년 1,665억 달러에서 2030년 5,035억 달러로 연평균 25% 성장하지만 데이터센터용 AI반도체 시장내 비중은 동기간 82%에서 약 60%로 낮아질 전망
 - 하이퍼스케일러의 ASIC 시장은 2025년 194억 달러에서 2030년 약 2,265억 달러로 연평균 65% 성장해 데이터센터용 AI반도체 시장내 비중은 동기간 10%에서 26%로 확대될 전망
 - 외부 판매용*으로 개발된 AI반도체 시장은 2025년 90억 달러에서 2030년 950억 달러로 연평균 66% 성장해 데이터센터용 AI반도체 시장내 비중은 동기간 4%에서 11%로 확대될 전망
- * 화웨이의 Ascend, AI반도체 스타트업의 칩 등을 포함



※ 참고: 엔비디아에 도전하는 차세대 AI반도체의 성능 비교

- 분석 대상 반도체는 엔비디아 A100/H100, AMD MI-300X, 인텔 Gaudi, 구글 TPuv5e, Cerebras CS-3, 삼바노바 SN40, Groq
- 최적의 AI반도체는 Batch size, Sequence Length, AI모델의 크기에 따라 달라짐
소규모 배치와 소형 모델에서는 S램 기반의 Cerebras와 Groq이 압도적 성능을 기록
처리량 요구가 증가할수록 삼바노바, AMD, 구글 TPU, 엔비디아의 칩이 토큰 생성 지연 시간과 에너지 소비량간 상충관계 측면에서 파레토 최적 경계(Pareto Frontier)에 근접
* Groq은 S램의 용량 제약으로 대형 모델 구동시 다수의 칩을 연결해야하며, 이 과정에서 칩간 데이터 송수신 부담이 커져 통신 병목현상 발생
- Cerebras와 삼바노바의 칩은 유휴 전력 소모가 크고, Decode 단계에서 전력효율이 급감하여 시스템 활용률이 높아야만 제조사가 공표한 전력효율을 달성할 수 있음
(Prefill) 모든 대상 반도체가 칩의 최대 성능(TDP)의 75~100%의 전력을 사용
(Decode) 엔비디아 GPU는 TDP의 45~60%를 사용하나, 삼바노바와 AMD MI-300은 TDP의 75~80%, Cerebras의 칩은 TDP의 100%를 사용
(유휴 전력) 엔비디아와 AMD의 칩은 TDP의 20% 수준이나, 삼바노바는 TDP의 40%, Cerebras는 TDP의 80%로 반도체가 작업을 수행하지 않아도 TDP 대비 전력 소비가 큼
- 신규 반도체의 도입을 가로막는 가장 큰 장벽은 소프트웨어 프로그래밍 용이성
엔비디아·AMD 외에는 구글 TPU와 인텔 Gaudi가 가장 우수하며, 삼바노바와 Cerebras는 Groq 대비 소프트웨어 Stack에서 우위

주요 AI반도체의 성능과 효율성 비교



주: 1/Latency는 지연시간의 역수로 1에 가까울수록 저지연

자료: Alicia Golden et al., "The xPU-athalon: Quantifying the Competition of AI Acceleration," 2026



※ 참고: 추론 영역에서 CUDA의 해자의 약화

- AI 컴퓨팅 스택은 프레임워크, 컴파일러, 라이브러리, 드라이버·런타임, 하드웨어로 구성됨
(프레임워크) 개발자가 표준화된 인터페이스를 통해 AI 모델 설계·학습·추론을 수행하도록 지원하는 상위 소프트웨어로 사용할 수 있는 컴파일러, 라이브러리, 하드웨어 범위를 결정
(컴파일러) 프레임워크의 고수준 코드를 하드웨어가 이해할 수 있는 기계어로 변환·중계하며, 이기종 프레임워크와 다양한 AI반도체 간의 상호 연계 및 중계를 담당
 - 컴파일러는 하드웨어의 이론적 최고 성능과 실제 성능간 격차를 줄이는 핵심 요인으로, 동일 하드웨어라도 컴파일러 최적화 수준에 따라 실제 처리량에 차이 발생
 - (라이브러리) 딥러닝 핵심 수식을 최적화한 알고리즘 라이브러리로 상위 소프트웨어는 칩의 구조를 몰라도 라이브러리가 제공하는 표준 함수로 칩의 성능을 향상시킴
 - (드라이버·런타임) 상위 라이브러리가 호출한 연산 명령을 실행할 수 있도록 하드웨어를 제어하는 시스템 최하단 계층으로, AI반도체 제조사가 개발하여 제공
 - (하드웨어) AI 컴퓨팅 스택의 최하위층 계층에 위치한 AI반도체는 고유의 연산 및 메모리 계층 구조를 가지므로, 해당 칩에 최적화된 소프트웨어가 수반되어야 최대 성능을 구현
- 엔비디아 CUDA 해자의 핵심은 주류 프레임워크의 CUDA 생태계를 최우선 지원, 약 20년간 축적된 라이브러리, 600만명의 개발자 생태계 등에 있음
주류 프레임워크인 PyTorch와 TensorFlow는 엔비디아 CUDA 생태계를 최우선 지원하며, 엔비디아가 자사 GPU에 특화하여 제공하는 라이브러리는 하드웨어 종속성을 높임
기업들의 운영 노하우와 최적화 코드베이스가 CUDA 플랫폼을 중심으로 축적되면서, 타사 반도체 플랫폼으로의 전환을 구조적으로 저해하는 진입장벽으로 작용

AI 컴퓨팅 Stack

계층	기능	예
프레임워크	AI모델을 개발·학습·배포하기 위한 상위 소프트웨어	Pytorch, TensorFlow
컴파일러	프레임워크의 코드를 하드웨어가 이해할 수 있는 기계어로 변환 및 중계	Triton, XLA
라이브러리	딥러닝 핵심 수식을 최적화한 알고리즘 라이브러리	cuDNN, cuBLAS
드라이버·런타임	AI 가속기 제어, 메모리 관리 등을 담당	
하드웨어	연산을 물리적으로 수행	GPU, NPU



- CUDA 해자는 학습·추론 워크로드 특성 차이, 컴파일러 중심의 하드웨어 종속 우회 기술 발전, 오픈소스 프레임워크와 서빙 엔진 등으로 학습 대비 추론 영역에서 상대적으로 약화되는 추세
학습에서는 엔비디아의 GPU·NVLink·NCCL 기반의 대규모 분산 학습 생태계와 라이브러리, 신규 모델의 CUDA 환경에서 우선 개발 관행 등으로 CUDA 해자가 견고하게 유지됨
추론 워크로드는 학습과 달리 연산 패턴이 상대적으로 정형화되어 있고, 칩의 성능보다 토큰당 비용·저전력·저지연이 중요하여 ASIC이 유리할 수 있음
과거에는 GPU를 제어하기 위해 CUDA 전용 프로그래밍이 사실상 필수적이었으나, 현재는 AI 추론을 중심으로 오픈소스 프레임워크와 서빙 엔진이 개발자 생태계의 표준이 됨
 - 오픈소스 딥러닝 프레임워크인 PyTorch와 TensorFlow는 파이썬 인터페이스를 제공하며, PyTorch는 엔비디아의 CUDA, AMD의 ROCm, 구글의 XLA를 공식 지원
 - 오픈소스 추론 서빙 엔진인 vLLM과 SGLang은 업계 표준으로 자리잡았으며, 이들은 엔비디아 GPU 중심으로 최적화되어 있으나 AMD, 화웨이 등의 다양한 AI반도체로 지원을 확장
 - AMD의 ROCm은 완성도가 낮았으나 PyTorch 지원 안정화 및 vLLM 등 추론 엔진 지원이 상용화 수준에 도달
- 오픈AI의 Triton 등 오픈소스 컴파일러는 파이썬을 통해 연산 코드를 자동으로 최적화·생성하여 CUDA 작성 부담과 엔비디아의 독점적 라이브러리 의존도를 완화시켜줌
 - Triton은 엔비디아 GPU를 대상으로 개발되었으나 현재는 AMD의 GPU도 지원
- CUDA 기반 코드를 타사 반도체용으로 이전하는 데 상당한 인력과 시간이 소요되었으나, 코딩 AI의 발전으로 타 반도체로 porting하는 전환비용이 낮아짐
- 그러나 기계적인 코드 변환만으로는 AI반도체의 구조적 차이 등으로 인해 최고 성능 구현에는 한계가 있음
AI반도체는 각각 고유한 명령어 체계(ISA), 메모리 계층 구조, 연산 유닛 배치를 가지며, 해당 칩에 최적화된 소프트웨어가 있어야 최고의 성능을 발휘
PyTorch는 지원하는 AI반도체를 확대하고 있으나 기술적 지원 깊이 등에서도 일부 차이가 있음
하이퍼스케일러는 자사 엔지니어를 통해 엔비디아 의존도를 낮추기 위해 노력중이나, 일반 기업 등은 CUDA 의존도가 높음



Ⅲ. 한국의 AI반도체 산업 현황

1. AI반도체 기업 현황 및 경쟁력

국내 데이터센터용 AI반도체의 대표 기업은 리벨리온과 퓨리오사AI로 2세대 NPU를 개발하고 상용화 직전 단계에 위치

리벨리온은 2020년에 설립되어 데이터센터를 타겟으로 2024년에 ATOM을 출시했으며, 2026년 하반기에 2세대 칩 REBEL 100을 출시할 계획

- ATOM은 중소형 AI 모델, REBEL 100(구 명칭 REBEL-Quad)은 초대형 AI 모델이 타겟으로, REBEL 100은 엔비디아가 2024년에 출시한 H200급의 성능을 보유
- ATOM은 SK텔레콤의 통화 요약 서비스 에이닷에 도입되어 상용화 레퍼런스를 확보
- REBEL 100은 4개의 칩렛(Chiplet)*을 하나의 칩처럼 구동시키며, HBM3E와 칩렛간 고속 통신 표준인 UCle-Advanced를 적용

* 기존 칩을 레고처럼 기능별로 분리하여 칩 조각(Chiplet)으로 제작한 후 하나로 패키징하거나 2개 이상의 SoC(System on Chip)가 동일 패키지에 연결되어 더 큰 SoC를 형성. 칩의 크기가 작을수록 단일 웨이퍼에서 생산되는 반도체의 수율이 높아지고, 칩 기능별로 필요한 기술 노드(공정)에서 생산하여 제조단가 절감, 칩 개발 속도 단축 등의 장점이 있음

리벨리온의 REBEL 100

회사		리벨리온	엔비디아	
제품		REBEL 100	H200	B200
제조공정		삼성 4나노	TSMC 4나노	TSMC 4나노
연산성능(FP16) ¹⁾		1,024 TFLOPS ²⁾	990 TFLOPS	2,250 TFLOPS
메모리	용량	HBM3E 144GB	HBM3E 141GB ³⁾	HBM3E 192GB
	대역폭(TB/sec)	4.8	4.8	8
카드	설계 전력(TDP)	600W	700W	1,000W

주: 1) 연산성능은 16bit 부동소수점(Floating Point) 연산 기준. FP 다음의 숫자가 클수록 정밀도는 높지만 속도는 느림

2) TFLOPS는 Tera Floating-Point Operations per Second(1초에 1조번 연산)

3) HBM3E 용량은 144GB이나 3GB를 에러정정코드(ECC) 등 보조 오버헤드 영역으로 할당해 실제 가용용량은 141GB

자료: 리벨리온.



- 리벨리온은 2024년 12월에 SK그룹의 AI반도체 기업 사피온과 합병하면서 국내 첫 AI반도체 유니콘기업(기업가치 10억 달러 이상 기업)으로 도약
- 2025년 매출은 320억원으로 국내 AI반도체 기업중 최대 규모이며, 2026년 매출 목표는 900억원
- 주요 투자자는 SK, KT, 삼성, 사우디 Aramco, 영국 반도체 IP 기업 Arm, 마벨, 대만 페가트론 등이며, 주요 구매자는 SK텔레콤과 KT
 - SK계열사(SK텔레콤, SK하이닉스, SK스퀘어)는 리벨리온의 최대 주주
 - 2026년 6월, KT클라우드는 공공기관 전용 클라우드에 리벨리온의 ATOM Plus를 적용한 NPUaaS(NPU as a Service)²¹⁾ 서비스 출시를 발표
 - 리벨리온은 중동의 소버린 AI 시장을 공략해왔으며, 2027년 상반기에 사우디 Aramco에 2세대 칩 REBEL 100을 공급할 계획²²⁾
- 2026년 4월, 리벨리온은 Arm, SK텔레콤과 협력하여 '차세대 CPU+NPU AI 추론 서버 솔루션' 공동 개발 계획을 발표
- Arm의 데이터센터용 CPU인 AGI CPU와 리벨리온의 칩을 결합한 AI 서버를 공동 개발하고 SK텔레콤의 AI 데이터센터에서 검증할 계획
- 기술 검증후 3사는 독자 AI 인프라 구축을 추진중인 글로벌 통신사와 공공 산업군을 중심으로 맞춤형 특화 솔루션을 공급할 계획

리벨리온의 제품 라인업

ATOM™ 데이터센터용 AI 반도체	ATOM-MAX 데이터센터용 AI 반도체	REBEL-QUAD 하이퍼스케일 데이터센터용 AI 반도체 '26 하반기 출시 예정
• AI 추론을 위한 시스템 온 칩(SoC) • PCIe Gen5 지원 및 지속 가능한 확장성 • 32 TFLOPS (FP16), 최대 128 TOPS (INT8) 성능 • 16GB GDDR6 메모리와 256 GB/s의 메모리 대역폭	• 대규모 AI 추론에 특화된 구조 • 탁월한 연산 성능과 고대역폭 메모리 접근성을 결합 • 128 TFLOPS (FP16), 최대 512 TOPS (INT8) 성능 • 64GB GDDR6 메모리와 1024GB/s의 메모리 대역폭	• UCle-Advanced 칩셋 아키텍처 기반 AI SoC • 전체 칩 단위 동기화 및 통신 구조를 제공 • 144GB HBM3E 메모리와 4.8 TB/s 메모리 대역폭
활용대상 (TARGET WORKLOADS) SLM Inference Vision AI	활용대상 (TARGET WORKLOADS) LLM Inference VLM Inference RDMA	활용대상 (TARGET WORKLOADS) LLM Inference VLM Inference RDMA Hyperscale AIDC

주: REBEL-Quad는 REBEL100으로 명칭이 변경됨
자료: 리벨리온.

21) NPU를 클라우드 환경에서 필요한 만큼 구독하여 사용하는 서비스

22) ZDnet, 리벨리온, 내년 사우디 아람코에 2세대 AI 추론칩 공급, 26.5.26



퓨리오사AI는 2017년에 설립되었으며 2023년에 1세대 칩 Warboy 양산, 2026년초부터 2세대 칩 레니게이드(RNGD) 양산을 시작

- 1세대 칩 Warboy는 Vision 연산에 특화된 NPU이며, 레니게이드는 대형 언어 모델 (LLM) 및 멀티모달 모델²³⁾의 효율적인 추론을 위해 설계된 데이터센터용 AI반도체
- Warboy는 Vision 연산에 특화된 NPU로 이미지 인식에 뛰어난 성능을 발휘하는 CNN (Convolutional Neural Network, 합성곱 신경망) 알고리즘을 지원
 - Warboy는 이미지·비디오 분석, 지능형 교통관리, 광학 문자인식 등을 위한 AI반도체로, 연산 성능은 64TOPS(INT8 기준)이며, 삼성 파운드리 14나노 공정을 이용
- 레니게이드는 현재 AI의 주류인 트랜스포머 알고리즘이 나온 뒤 개발되어 대형언어모델 (LLM)을 지원하며, 타겟은 엔터프라이즈(기업) 및 데이터센터 시장
 - 레니게이드는 TSMC 5나노 공정을 이용하며 메모리는 SK하이닉스의 HBM3 48GB 탑재, 연산 성능(FP8)은 512TFLOPS, 열 설계 전력(TDP)은 180W으로 저전력이 강점
 - 레니게이드는 기존 표준 공랭식 데이터센터 환경에서 바로 운용할 수 있음
 - 퓨리오사AI는 레니게이드가 엔비디아의 워크스테이션 및 데이터센터용 GPU인 RTX PRO 6000과 비교시 동일 전력 기준으로 최대 7.4배 많은 사용자를 동시에 처리할 수 있어 데이터센터 인프라 총소유비용(TCO)을 GPU 대비 약 40% 절감할 수 있다고 밝힘
 - 레니게이드를 2026년에 약 2만장을 양산할 계획이며, 제품군을 세분화하는 전략하에 HBM3E를 탑재하는 RNGD+, GDDR을 탑재해 60W 저전력을 구현하는 레니게이드S 등으로 라인업을 확대할 계획
- 2025년 7월, 퓨리오사AI는 LG AI연구원이 자사의 LLM 모델 엑사원(EXAONE)을 구동하는 서버에 레니게이드 칩을 도입한다고 발표
 - LG AI연구원은 8개월간 레니게이드 칩을 테스트한 결과 기존 GPU(엔비디아 A100('20년 출시) 대비 전력효율이 2.25배 향상되었다고 밝힘

퓨리오사AI의 주요 제품 로드맵

제품	메모리	출시 및 양산 시점
Warboy	LPDDR4X	2023년 양산
레니게이드(RNGD)	HBM3 48GB	2026년 1월 4000장 출하, 연내 2만장 목표
레니게이드+(RNGD+)	HBM3E 72GB	2026년 하반기 양산
레니게이드+맥스(RNGD+MAX)	HBM3E 144GB	2026년 하반기 양산
레니게이드S	GDDR	2026년말~2027년초 출시 예정

자료: ZDNet, 시사저널e.

23) 텍스트, 이미지, 비디오, 오디오 등 다양한 유형의 데이터를 처리하는 AI



- 퓨리오사AI는 2025년 7월말에 시리즈 C²⁴⁾ 브릿지 라운드에서 총 1,700억 원 규모의 투자를 유치하면서 국내 두번째 AI반도체 유니콘기업으로 도약
- 2025년 매출은 57억원으로 전년 대비 93% 증가했으며, 제품 매출은 35억원, 서비스 매출²⁵⁾은 22억원을 기록
 - 퓨리오사AI의 매출은 리벨리온 매출의 약 20% 수준으로, Warboy의 타겟인 CNN 시장이 칩 출시 직후 트랜스포머 중심으로 재편되면서 충분한 상용화 레퍼런스를 구축하지 못한 것으로 추정
- 주요 투자자는 네이버 D2SF, DSC인베스트먼트, 산업은행, 기업은행 등
- 삼성SDS는 2026년 7월에 삼성 클라우드 플랫폼을 통해 레니게이드를 기반으로 한 'NPUaaS'를 출시
- 2026년 7월, 퓨리오사AI는 Colocation²⁶⁾ 데이터센터 기업 에퀴닉스와 협력해 에퀴닉스의 포르투갈 LS2 데이터센터에 레니게이드 서버를 구축하고 유럽을 공략할 계획을 발표
 - 해당 서버는 기업들이 실제 AI 모델과 워크로드를 기반으로 레니게이드의 성능을 직접 검증할 수 있게 운영할 계획
- 퓨리오사AI는 브로드컴의 턴키 서비스를 이용해 2028년에 3세대 칩 스톡 양산을 추진
- 양사는 칩렛 기반의 3세대 칩을 공동 개발하고 브로드컴의 네트워킹 기술 등을 결합하여 대규모 추론 클러스터를 지원하는 통합 플랫폼 구축을 추진
- 3세대 칩은 2나노 공정을 이용하고, HBM4/4E 메모리를 적용할 전망

하이퍼엑셀은 2023년에 설립된 AI반도체 스타트업으로 거대 언어 모델(LLM) 추론에 특화된 LPU(LLM Processing Unit)를 개발하고 2027년에 양산을 추진

- 하이퍼엑셀의 LPU인 Bertha는 기존 NPU가 다양한 AI 모델을 지원하는 것과 달리 트랜스포머 기반의 LLM 추론에만 집중
- Bertha는 삼성 파운드리 4나노 공정을 사용하며, 고가의 HBM 대신 LPDDR5X를 탑재해 기존 GPU 대비 1/10 가격에 공급 추진
- 칩 양산 후에는 네이버클라우드 데이터센터 적용을 목표로 기술검증(PoC)을 진행중

24) 시리즈 A·B·C는 스타트업이 자금을 조달하는 단계를 의미하며, 시리즈 A는 제품·서비스를 출시하기 위해, 시리즈 B는 사업을 확장(Scale-up)하기 위해, 시리즈 C는 신제품 개발, 신시장 진출 등을 위한 자금 조달 단계

25) 제품을 고객사 환경에 맞추는 일로 소프트웨어 개발, 칩 최적화, 기술지원, 컨설팅 등

26) 고객에게 데이터센터 시설의 전력, 공간 및 관리 서비스를 임대하여 운영

- 미국, 중국 등 소수 국가만이 상용 수준의 AI반도체를 개발했으며, 한국의 AI반도체 설계 기술은 선도국인 미국 대비 3년 수준의 기술격차가 있음
- 데이터센터용 AI반도체를 자체 개발한 국가는 미국, 영국, 캐나다, 중국, 이스라엘, 한국 등으로 제한적
 - 아시아태평양의 AI반도체 유니콘 기업은 리벨리온, 퓨리오사AI, 중국 캄브리콘 등으로 소수
- 단일 칩 설계 수준에서 선도국과 격차는 3년으로 평가되나, 인터커넥트, 첨단 패키징, Full-stack 시스템 아키텍처 수준에서는 선도국가 기술격차가 3년 이상
- 우리기업은 자본력, 대규모 상용화 경험, 생태계 등에서는 선도기업과 격차가 있음
- 미국 주요 AI반도체 스타트업은 글로벌 VC 등으로부터 대규모의 장기 인내 자본을 수혈받아 대규모 R&D를 집행하고 선제적으로 양산
- 우리기업은 높은 개발비용과 불확실한 회수기간 등으로 시제품 개발 성공 이후 칩 양산 직전에 자금 고갈 위험은 겪은 사례가 있음
 - 반도체 설계에서 양산까지 약 2년이 소요되며, 리벨리온과 퓨리오사AI는 2025년 매출의 4~6배를 R&D에 투자
- 우리 AI반도체 기업은 기술력은 입증했으나 대규모 상용 서비스 실증 경험 부족, 소프트웨어 스택의 완성도 등의 제약을 받고 있음
 - 리벨리온의 RBLN SDK가 300개 이상의 레퍼런스 모델을 지원하며, vLLM을 공식 지원하여 서빙 생태계와 호환성도 확대하고 있으나 CUDA 생태계와 비교시 아직 초기 단계


주요국의 데이터센터용 AI반도체 기업



자료: Yole.




주요 AI반도체별 소프트웨어 스택



자료: 소프트웨어정책연구소.

리벨리온의 소프트웨어 스택



자료: 리벨리온.



2. 정부의 육성정책

2025년 12월 18일, 정부는 'AI반도체 산업 도약 전략'을 수립하고 K-엔비디아 육성을 통해 2030년까지 글로벌 AI반도체 유니콘 기업 5개사 창출을 목표로 설정

- (기술혁신) 국산 AI반도체 상용화를 위해 K-NPU 프로젝트를 가동하고, AI컴퓨팅 인프라 기술자립 등을 추진
 - K-NPU 프로젝트는 국산 NPU와 독자 AI파운데이션모델의 패키지 구현을 위해 국산 NPU 테스트베드 구축(155PF) 및 AI반도체 전주기 사업화 지원체계 구축을 추진
 - LLM향 NPU 성능 고도화 및 유효성능 확보를 위한 소프트웨어 최적화를 지원(~'27)
 - AI반도체 성능평가 지표인 K-Perf를 통해 표준화된 NPU 성능 공유 및 피드백 체계를 확립
 - AI 컴퓨팅 인프라 기술자립화를 위해 국산 AI서버 개발, 엔비디아 CUDA에 대응하는 개방형 K-NPU 소프트웨어 생태계* 구축 등을 추진
 - * 오픈소스로 시스템SW부터 클라우드까지 Full-stack 개발
- (수요창출) 공공 AX에 국산 AI반도체를 도입하여 초기시장 마중물 제공, 민관 합작 '국가 AI컴퓨팅 센터'에서 NPU 실증, 국산 NPU+AI서비스 패키지의 해외실증 등을 추진
 - K-NPU 공공 선도 7대 과제(치안·국방 등), 4대 주력산업(자동차, 가전, 기계·로봇, 방산)과 연계한 'K-온디바이스 AI반도체 상용화 기술 개발' 지원 등을 추진
- (기반강화) 국민성장펀드 기반 대투모 투·융자 지원, NPU 기반 AI컴퓨팅 인프라·설비 통합투자 등에 대한 세액공제 신설 등을 추진


AI반도체 산업 도약 전략의 비전 및 목표



자료: 과학기술정보통신부, 산업통상자원부.



K-AI+NPU 패키지 구현 기본방향



자료: 과학기술정보통신부, 산업통상자원부.

2026년 3월, 국민성장펀드는 향후 5년간 50조원을 AI·반도체 분야에 투자할 계획을 발표했으며, 이후 리벨리온, 퓨리오사AI, 국가AI컴퓨팅센터 등에 투자

- 국민성장펀드는 첨단전략산업에 5년간 150조원을 공급할 계획이며, 이중 50조원을 AI와 반도체 분야에 집중 투자할 계획
- K-엔비디아 육성 프로젝트의 일환으로 리벨리온에 2,500억원, 퓨리오사AI에 8,000억원을 직접투자
 - 리벨리온에 첨단전략산업기금 2,500억원, 산업은행 500억원, 민간 투자자(미래에셋 등)이 3,000억원을 투자 (총 6,000억원)
 - 퓨리오사AI에 첨단전략산업기금 3,700억원과 산업은행 300억원을 결합해 총 4,000억원의 정책금융을 먼저 투입하고 나머지 4,000억원은 민간 투자자 몫으로 배정²⁷⁾
- 국가AI컴퓨팅센터 구축사업에 4,000억원을 투자하고, 향후 본 사업에 대한 최대 2조원 이상의 대출도 추진할 계획
 - 전남 해남군 솔라시도에 민관이 합동으로 AI반도체 1.5만장 규모의 데이터센터를 2028년까지 구축하며, 국산 NPU의 품질향상을 위한 테스트베드로도 활용할 계획
 - * 국산 NPU 50% 도입 의무 등이 부과되었으나 국가AI컴퓨팅센터 사업이 두 차례 유찰되자 국산 NPU의 완성도 등을 고려하여 의무 조항이 삭제됨
 - 국가AI컴퓨팅센터 구축을 위한 특수목적법인 한국AI컴퓨팅센터의 지분률은 삼성SDS 30%, 정부 29%, 네이버클라우드가 26.1% 순

27) DealSite, 1000억 못 모은 퓨리오사에...나랏돈 4000억 집행, 2026.6.5



과학기술정보통신부는 2025년부터 'AI반도체 해외실증 지원 사업'을 지원하며, 최근에는 AMD와 국산 NPU를 연계하는 이기종 AI 컴퓨팅 구축·실증을 위한 업무협약을 체결

- AI반도체 해외실증 사업은 AI반도체 기업과 서비스 기업 컨소시엄이 2년에 걸쳐 실증을 수행하고 Reference를 확보할 수 있도록 지원
- 해외실증 사업은 서버형과 엣지형으로 나눠 공모하며, 2년 동안 해외 실증 환경 구현, 현지 맞춤형 AI 모델 조정 등을 거쳐 현지화를 진행
 - 1차년도에는 AI반도체 최적화, AI 솔루션 현지화, 현지 실증 사이트 설치 등 실증 기반 마련에 집중하고, 2차년도에는 AI반도체와 서비스 패키지를 실제로 운용
- 2026년 5월에는 AI반도체 해외실증 지원 사업의 신규 과제로 8개의 컨소시엄을 선정
 - 메가존 클라우드는 퓨리오사AI 등과 KRFSAI(Korea Full Stack AI) 컨소시엄을 구성해 아람코 디지털의 인프라 환경에 퓨리오사AI의 NPU 서버를 구축하고, 플랜트 엔지니어링 2D 도면을 AI로 파싱해 산업용 3D 디지털 트윈 Asset을 자동 생성하는 서비스를 구현·실증할 계획

2026년 AI반도체 해외실증 지원 신규사업

주관기관	참여기관	실증 국가	과제 내용
그린블루	딥엑스, 유원지리 정보시스템, 클레이웍스	인도네시아	현지 교차로 내 교통량 등 통합관제 시스템
덕성	딥엑스, 알체라	말레이시아	구리 제련 공정 관리 스마트팩토리 솔루션
누리인포스	에프와이디, 온팜	뉴질랜드	온도·습도 등 이상 감지 양봉 솔루션
노타	모빌린트	UAE	AI기반 도로 내 돌발상황 감지시스템
메가존 클라우드	퓨리오사AI, 엔씨AI, 업스테이지, 유라클	사우디 아라비아	플랜트 디지털 트윈을 위한 LLM & 3D모델링 통합플랫폼 서비스
피아스페이스	하이퍼엑셀	태국	커피체인 사업 제조·리테일 플랫폼 AX 전환
브레인웍스	엣지에이아이, 제이아이엔시스템	인도네시아	도로 상태(균열, 차선훼손 등) 판별 솔루션
다운아이앤씨	하이퍼비주얼AI	인도네시아	불법 환적·밀수 등 해양 통합관제 플랫폼

자료: 과학기술정보통신부.

- 2026년 7월에 과기정통부는 AMD와 'AI반도체 생태계 협력에 관한 양해각서'를 체결하고 AMD의 CPU·GPU와 우리기업의 NPU를 연계하는 AI 컴퓨팅 인프라 구축·실증 등을 추진
- AI반도체 기업 뿐만 아니라 메모리, DPU, CXL, 네트워크, 서버 등 관련 국내 기업들이 참여하는 개방형 AI 컴퓨팅 생태계 조성을 통해 글로벌 AI 컴퓨팅 공급망에 참여할 수 있는 Reference 모델을 확보해 나갈 계획



IV. 결론 및 시사점

AI반도체는 한국의 시스템반도체 경쟁력 제고, 국가안보와 공급망 리스크 관리, AI 산업 육성, 주력산업 경쟁력 제고 등에 기여할 수 있어 정책적 지원이 요구됨

- 한국은 메모리반도체 강국이나 시스템반도체 경쟁력은 상대적으로 취약한 상황이며 추론용 AI반도체는 성장 초기 단계로 한국이 시스템반도체 경쟁력을 제고할 기회
- 우리나라의 시스템반도체 세계시장점유율은 지난 10년간 3% 수준에서 정체됨
- 시스템반도체 시장규모는 메모리반도체 대비 변동성이 낮아 메모리반도체에 편중된 한국 반도체산업의 변동성을 완화할 수 있음
- '팹리스-파운드리'간 유기적 협력관계 구축을 통해 AI반도체 기업의 성장이 국내 파운드리의 성장을 견인하는 선순환 구조 구축 가능
- AI반도체 육성은 해외 의존도를 낮추고 제조업 경쟁력 강화, AI 서비스 상용화 등에 기여할 수 있음
- AI반도체는 엔비디아 GPU 의존도가 높았지만 AI 추론 시장 성장이 본격화되면서 국산 AI반도체의 시장진입 기회가 넓어질 전망
- 고성능·저전력 추론이 확산되면 AI 전환이 중소기업까지 확산되고 한국의 주력 산업 전반의 생산성 향상으로 이어질 전망

국산 AI반도체 상용화의 병목은 소프트웨어 최적화 부족과 실사용 환경에서 검증된 운영 실적 부족으로 소프트웨어 Stack 강화와 Reference 구축 지원 확대 등이 필요

- 국내 AI반도체 스타트업은 높은 칩 개발비용과 불확실한 수요로 자금조달에 어려움을 겪었으나, 국민성장펀드의 투자 등을 통해 투자비 부담을 일정 부분 완화
- 반도체 설계에서 양산까지 최소 수천억원의 비용 소요되며, 높은 개발비용과 불확실한 회수기간으로 칩 양산 단계에서 자금 부족을 겪은 사례가 있음
- 대규모 양산 전까지는 수익을 내기 어려워 퓨리오사AI와 리벨리온의 2025년 매출은 각각 320억원, 57억원, 영업손실은 각각 1,205억원, 625억원을 기록
- AI반도체 경쟁이 연산성능에서 Full-stack 제품 완성도로 변화하여, 소프트웨어 경쟁력 제고를 위해 오픈소스 생태계 참여 확대, AI반도체 소프트웨어 전문 인력 양성 지원 등이 필요
- 동일 AI 반도체를 사용하더라도 컴파일러, 프레임워크, 가속 라이브러리 등 소프트웨어 최적화 수준에 따라 실제 처리량(Throughput)은 3배 이상 차이가 발생



- 국산 AI반도체는 프레임워크 계층 진입에 성공했으나 컴파일러, 라이브러리 계층의 성능 격차와 운영 Reference가 부족²⁸⁾
- 국산 AI반도체는 실사용 환경에서 검증된 Reference가 부족하여 시장진입에 어려움을 겪고 있어 정부의 Reference 구축 지원 확대가 필요
- 수요기업은 상용 Reference가 없는 AI반도체를 도입시 소프트웨어 마이그레이션 비용과 성능 불확실성 등의 리스크를 감당하기 어려워 검증된 제품을 선호
- 정부의 실증지원사업은 국산 AI반도체의 초기 시장 형성에 기여하고 있으나 실증 성과가 민간 구매로 이어질 수 있도록 수요 기반 인센티브 설계와 관련 정책간 연계 강화가 필요
- 국산 AI반도체를 사용하는 기업에 세제 혜택이나 보조금 지원 등을 통해 기업의 위험 부담을 경감할 수 있는 제도적 장치에 대한 모색이 필요
- 정부는 'AX 원스톱 바우처' 지원사업(26년 260억원)을 통해 AI, 클라우드, 데이터 구매·가공을 지원하며, 국산 AI반도체 기반 클라우드 사용 연계를 통해 추가적인 시너지를 창출할 수 있을 전망
- * 동 사업은 국산 AI 파운데이션 모델 최소 1개 이상 사용을 의무화하고 있으나, 하드웨어(반도체, 클라우드 인프라)에 대해서는 국산화 유인이 부재

2026년은 AI 산업이 추론 중심으로 재편되는 전환점으로 한국 AI반도체 기업은 소버린 AI 프로젝트, AI 추론 비용 효율화를 추진하는 기업 등과 협력할 기회가 있을 전망

- 세계 주요국은 자국의 언어, 문화 등을 학습시켜 자국의 환경에 맞는 AI 모델을 자체 개발하거나 데이터 주권을 강조하는 '소버린 AI' 전략을 추진
- 소버린 AI는 각국이 자체 인프라, 데이터 등을 활용해 독자적인 AI 역량을 구축하는 것으로, 특정 국가·기업의 영향력에서 벗어나 AI 주권을 지킬 수 있음
- 중동·유럽 등이 국가안보, 지정학적 이슈 등으로 AI반도체 공급처 다변화를 추진하고 있어 한국기업의 해외진출에 대한 정부의 외교적 지원 등이 필요
- 중동 등은 AI반도체 수출 규제 리스크, 고가의 엔비디아 GPU 사용에 따른 투자비 부담과 전력·부지 제약 등으로 다수의 국가와 기업은 엔비디아의 대안을 모색중
- 유럽 등은 전력·냉각 인프라 등의 제약으로 기존 공랭식 데이터센터에서도 운영할 수 있는 AI반도체를 선호하는 것으로 보임
- * 세계 데이터센터의 약 85%가 공랭식 기반으로 운영되며, 주요 AI반도체 스타트업 등의 칩은 데이터센터를 수냉식 등으로 개조할 필요 없이 기존 환경에 설치하여 빠르게 운영 가능

28) 소프트웨어정책연구소



- 정부 차원에서 우리기업이 글로벌 공급망에 편입될 수 있는 협력 기회 발굴이 필요
 - 2023~2025년은 대형언어모델(LLM)의 학습의 시대였으나, 2026년은 AI 모델이 실질적인 업무와 서비스 현장에 대규모로 적용되는 추론의 시대로 전환
 - 정부가 AMD와 'AI반도체 생태계 협력에 관한 양해각서'를 체결하고 AMD의 CPU·GPU와 우리 기업의 NPU를 연계하는 AI 컴퓨팅 인프라 구축·실증 등을 추진하는 사업은 소버린AI와 연계해 한국 반도체의 글로벌 공급망 편입 기반을 마련한 시도로 평가됨
 - 동 협력이 수출 성과로 이어질 수 있도록 정부 차원의 글로벌 협력을 지속 확대할 필요가 있음
- AI반도체 시장은 3~5년내에 AI반도체 스타트업의 생사 여부가 결정되고, 업계 통합이 가속화될 것으로 예상되어 우리기업의 조기 Reference 확보가 중요할 전망



참고문헌

한국공학한림원, 'AI 반도체 강국도약 가이드라인', 2026.1

관계부처 합동, 'AI 시대, 반도체산업 전략', 2025.12.10.

관계부처 합동, '공동조달을 통한 AI 산업 활성화 선도 방안', 2026.2.4

과학기술관계장관회의, 'AI반도체 산업 도약 전략(안)', 2025.12.18

미래에셋증권, '엔비디아 GTC 2026 – AI 팩토리의 탄생', 2026.3.20

ZDNet, 리벨리온, '차세대 AI칩 '리벨 100'으로 명칭 변경...왜?', 2026.3.30.

더에이아이, '엔비디아 독점 시대, 국산 NPU가 바라본 틈은?', 2026.5.29

Goldman Sachs, 'AI Unit Economics: GPUs vs. ASICs and the inference cost curve, 2026.1.20.

Counterpoint, 'AI Server Compute ASIC Shipments to Triple by 2027 as Custom Silicon Enters Hyper-Growth Phase', 2026.1.26.

DigitalOcean, 'Prefill/Decode Disaggregation: Why Production LLM Inference Is Splitting Onto Separate Hardware', 2026.7.15.

EETimes, 'Untether AI Shuts Down, Engineering Team Joins AMD', 2025.6.9