

Physical AI 시대에 대응한 On-device AI 반도체 경쟁력 강화 방향

김민식* · 오정숙**

Abstract

최근 다양한 수요 산업 분야를 대상으로 하는 Physical AI 실현을 위해, 맞춤형 On-device AI 반도체 수요가 증가할 것으로 예상된다. 이에 주요 반도체 기업은 Physical AI 구현을 위한 On-device AI 반도체 관련 HW·SW 기술 주도권을 확보하여, 기존 AI 반도체의 경쟁 구도를 변화시키고자 노력하고 있다.

따라서 본 고에서는 Physical AI 및 On-device AI의 개념과 이를 지원하는 On-device AI 반도체에 대한 시장 전망에 대하여 살펴보고, 수요처 Device 별 맞춤형·최적화에 대한 국내외 반도체 관련 기업전략에 대하여 분석한다. 이러한 분석을 바탕으로 On-device AI 반도체 지원 정책을 살펴보고 향후 국가경쟁력 강화 방향과 시사점을 제언한다.

I. 서론

첨단 AI 반도체 분야의 경쟁은 이를 활용하는 최종 수요 제품의 변모에 따라 변화하고 있다. 과거 메인프레임, 서버, PC, 모바일 시대를 거쳐, 현재는 인공지능인 Chat GPT와 같은 클라우드 기반의 생성적 AI(Generative AI)에서 개별 Device 별로 맞춤형 AI 기술이 제공되는 물리적 AI(Physical AI)로 발전할 전망이다.

이러한 AI 기술 패러다임의 변화에 따라, 이를 지원하는 AI 반도체(AI Semiconductor) 시장도 데이터센터 수요처 중심의 범용성·고성능 지향 추세에서 벗어나 수요처 Device 별

* 정보통신정책연구원(KISDI) 디지털플랫폼경제연구실 부연구위원, kimmin@kisdi.re.kr

** 정보통신정책연구원(KISDI) 디지털플랫폼경제연구실 부연구위원, redrock5@kisdi.re.kr

맞춤형·최적화로 전환될 전망이다. 특히 최근 다양한 수요 산업 분야를 대상으로 하는 Physical AI 실현을 위해, 맞춤형 On-device AI 반도체 수요가 증가할 것으로 예상된다.

관련 On-device AI 반도체 시장은 현재 초기 형성 단계로 기존 반도체 업체들은 이러한 시장 성장 기회의 선점을 위한 역량 확보에 나서고 있다. 현재 주요 반도체 기업들은 Physical AI 구현을 위한 On-device AI 반도체 관련 HW·SW 기술 주도권을 확보하여, 기존 AI 반도체 구도를 변화시키고자 노력하고 있다.

이에 본 고에서는 Physical AI 및 On-device AI의 개념과 이를 지원하는 On-device AI 반도체에 대한 시장 전망에 대하여 살펴보고, 수요처 Device 별 맞춤형·최적화에 대한 국내외 반도체 관련 기업전략에 대하여 분석하고자 한다. 이러한 분석을 바탕으로 On-device AI 반도체 지원 정책을 살펴보고 향후 경쟁력 강화 방향과 시사점을 제언한다.

II. Physical AI 구현을 위한 On-device AI 반도체 이해

1. Physical AI와 On-device AI

Nvidia는 Physical AI의 개념을 『로봇, 자율주행차, 스마트 공간과 같은 자율 시스템(autonomous systems)이 실제의 물리적 세계(physical world)에서 복잡한 동작을 인식 및 이해하고 수행하는 것』으로 설명한다.¹⁾ 그리고 통찰력과 행동(insights and actions)을 생성하는 능력을 강조하여 “생성적 물리적 AI(generative physical AI)”라고도 표현한다.

Physical AI 이전에는 자율 기계(autonomous machines)가 주변의 실물 환경을 인식 및 감지하는 것에 한계가 존재했으나, Physical AI를 통해 자율기계가 현실 세계의 주변 환경과 원활하게 상호작용하고 적응하도록 제작하고 훈련할 수 있다.²⁾

특히 Physical AI는 생성적 AI(Generative AI)에 공간적 관계와 물리적 행동에 대한 이해를 추가하여 범위를 확장한다. 이를 위해 Physical AI는 AI 훈련 과정에서 실제 세계의 공간적 관계와 물리적 규칙에 대한 정보가 담긴 추가 데이터를 활용한다.


따라서 Nvidia에 따르면 Physical AI 구축에는 자율기계를 훈련할 수 있는 강력한 물리 기반 시뮬레이션(physics-based simulations) 필요하며, 이는 자율기계가 복잡한 작업을

1) Nvidia웹페이지, <https://www.nvidia.com/en-us/glossary/generative-physical-ai/>.

2) 2023년 미국 샌프란시스코에서 로봇(자율주행) 택시가 네트워크 연결 장애로 도심 도로에서 집단 정지되는 사건이 발생하였는데, Physical AI가 On-device AI 방식으로 구현되면 이러한 문제를 해결할 수 있다.

수행하는 데 있어 효율성과 정확성을 향상할 뿐만 아니라, 인간과 기기 사이의 더욱 자연스러운 상호작용을 촉진하여 실제 애플리케이션의 접근성과 기능성을 향상한다.³⁾

그림 1 Nvidia가 제시한 인공지능 발전단계




주: 1) Perception AI: 데이터를 분석하고 패턴을 찾는 AI
 2) Generative AI: 텍스트, 이미지, 음악 등을 생성하는 AI
 3) Agentic AI: 목적을 수행하기 위한 계획을 수립하고 필요한 도구를 활용하여 실행하는 AI
 출처: 연합뉴스(2025. 1. 7)

이러한 Physical AI는 다양한 수요처 서비스에 특화된 형태로 경량화된 소형 AI 모델을 활용하는 Edge AI⁴⁾ 및 On-device AI 방식으로 구현된다. 이를 통해 대형 AI 모델 중심의 Cloud AI 방식으로 운영되는 Generative AI가 가지는 구축 비용, 에너지 소모, 처리 지연, 개인정보 보안 문제 등의 한계점이 개선되어, ① 실시간 연산, ② 높은 보안성, ③ 낮은 네트워크 의존성, ④ 저전력 등을 기대할 수 있다.⁵⁾⁶⁾ 이는 Edge AI, On-device AI 등의 방식으로 운영되는 Physical AI가 다양한 수요처에 특화되어 경량화된 소형 AI 모델을 적용하여 자율기계 및 Device의 한정된 컴퓨팅자원을 효율적으로 활용함으로써 데이터를 처리하고 추론 과정 중심의 결과물을 제공하기 때문이다. 단, 본 고에서는 Cloud AI 방식이 아

3) Nvidia 웹페이지, <https://resources.nvidia.com/en-us-playlist-for-robotics/sensor-simulation>.
 4) 대형 AI 모델과 함께 운영·관리되는 형태로 대형 AI 모델은 학습·추론을 통한 전반적인 AI 모델 성능을 향상하고, 소형 AI 모델을 지속적으로 업데이트시키는 역할을 한다.
 5) 산업통상자원부(2025. 5. 20)
 6) CITI(2024)

닌 산업현장의 자율기계 및 다양한 Device에서 Physical AI가 수행된다는 측면에서 On-device AI가 Edge AI를 포함한다고 분석한다.

그림 2 클라우드 AI, 엣지 AI, 온디바이스 AI 방식



출처: 삼성 KPMG 경제연구원(2024)

표 1 대형 및 소형 AI 모델 비교

구분	대형 AI 모델	소형 AI 모델
주요형태	LLM(Large Language Model)	sLM(small Language Model)
	LMM(Large Multi Modal Model)	sLLM(smaller Large Language Model)
매개변수 수	1천억 개 이상	10억~수백억 개 수준
사용 목적	다양한 태스크를 수행하는 범용 AI	특정 태스크에 특화된 목적 기반형 AI
훈련 비용	매우 높음	낮음
추론 비용	높음	낮음
주요특징	- 대용량 데이터 학습 - 모델 규모 큼 - 태스크 수행에 필요한 인프라 수준 높음 - AI 서비스 운영비용 큼 - 결과 도출 속도 늦음	- 대형 AI 모델 학습 데이터 기반한 특정 태스크 특화 형태 - 작은 규모의 모델로 운영 - 개별 태스크 수행을 위한 인프라 수준 낮음 - AI 서비스 운영비용 비교적 낮음 - 결과 도출 속도 빠름

출처: 한국저작권위원회(2024)

2. Physical AI 구현을 위한 On-device AI 반도체의 맞춤화·최적화

앞에서 살펴본 바와 같이 Physical AI를 현실 세계의 자율기계 및 다양한 Device에 적용하여, 이를 구현 및 지원하기 위해서는 낮은 전력 소모에 효율적으로 활용되는 On-device AI 반도체가 필수적이다. 구체적으로 Physical AI를 다양한 자율기계 및 다양한 Device에서 실제로 실현하기 위해서는 On-device AI 반도체의 맞춤화 및 최적화가 요구된다.

첫째, Physical AI를 지원하는 On-device AI 반도체를 맞춤형으로 개발하는 것이 필요하다. 제한된 하드웨어 자원(낮은 전력소모 및 메모리 탑재 수준)을 전제로, 반도체 기업은 목표로 하는 수요처의 특성을 고려하여 설계된 On-device AI 반도체를 제공해야 한다. 예를 들어 자동차 분야는 실시간 안전 기준과 내구성에 초점을 맞추고, 또 모바일 및 IoT 분야는 에너지 효율 및 데이터 보안에 초점을 맞춘다. 이에 따라 Smart-Speaker, Security-camera, Machine-vision, Drone, Automotive, Robotics, Edge-sever, Head-Mounted-device 등과 같은 다양한 수요분야에서 요구되는 특성에 맞추어 On-device AI 반도체를 설계하는 것이 경쟁의 축이 된다. 현재 On-device AI 반도체 기업들은 응용 분야별 맞춤형 제품 개발 전략을 추진하고 있다.

둘째, 맞춤형으로 개발된 On-device AI 반도체를 효율적·효과적으로 활용할 수 있도록 최적화를 지원하는 기술 계층(Full Stacks)도 매우 중요하다. On-device AI 반도체와 통합적으로 제공되는 기술 계층은 반도체 설계 단계에서부터 요구하는 성능, 전력 효율, 시스템 안정성, 수요처 활용성을 함께 고려해 제공하기 때문에 수요자에게 매우 중요한 기술이

표 2 On-device 반도체의 기술 계층(Full Stack) 예시

On-device AI Full Stack	AI 서비스 및 애플리케이션
	Inference Engine Layer(경량화 및 최적화된 라이브러리)
	Model Conversion 및 Optimization Layer
	Driver 및 interface Layer
On-device AI Hardware	On-Board module for On-device AI semiconductor
	On-device AI semiconductor

- 주: 1) On-Board module for On-device AI semiconductor: AI 반도체(NPU, DSP, ASIC 등)와 이를 지원하는 부품(메모리, 인터페이스, 전원 관리, I/O 인터페이스 등)을 하나의 모듈에 통합한 하드웨어 보드
 2) Driver 및 interface Layer: AI 반도체 최적화된 연산 배치를 수행하며, 쉽게 활용할 수 있도록 인터페이스와 드라이버를 제공
 3) Model Conversion 및 Optimization Layer: AI 모델을 AI 반도체에서 실행할 수 있도록 경량화, 변환, 최적화
 4) Inference Engine Layer: AI 모델을 구동하고 데이터를 처리하여 추론 결과 출력


출처: 저자작성

다. 예를 들어 On-device AI 반도체와 동시에 제공되는 소프트웨어 SDK(Software development kit), 라이브러리, 개발 도구를 활용해 수요처 개발자는 더욱 쉽게 고성능 AI 애플리케이션을 개발할 수 있다. 이러한 기술 계층 구성은 특정 하드웨어 및 활용되는 수요처에 따라 다르며, 개별 AI 반도체 제조사의 기술 계층은 지속적으로 업데이트 된다.

3. Physical AI 구현을 위한 On-device AI 반도체 시장 규모와 전망⁷⁾

Physical AI 현실화가 진전됨에 따라 향후 On-device AI 반도체가 전체 AI 반도체 시장 성장을 견인할 것으로 전망된다. Omdia에 따르면, On-device AI 반도체 시장은 2026년부터 클라우드 및 데이터센터용 AI 반도체 시장 증가율을 추월하여 2029년까지 연평균 12.6%씩 성장할 것으로 기대된다. 반면, 클라우드 및 데이터센터용 AI 반도체 시장은 2023년에 이어 2024년까지 각각 254.2%, 121.6% 연이어 고속 성장하였으나 2025년 48.5%로 성장세가 둔화한 후 2026년부터 2029년까지 연평균 성장률은 5.3%의 한 자릿수대로 축소될 것으로 전망된다. 이는 클라우드 및 데이터센터용 AI 반도체 시장에서 2024년 기준 71.7%의 비중을 차지하는 클라우드 분야의 성장이 정체될 것으로 예상되고, 수요처가 클라우드 및 데이터센터로 수요가 한정적이라 신규 수요를 창출하는데 한계가 있기 때문이다.

그림 3 전세계 클라우드/데이터 센터 AI반도체^{*}와 On-device AI반도체^{**} 시장전망(2023~2029)




주: 매출액 기준임

출처: *Omdia(2024. 7), **Omdia(2024. 12) 기반 저자 재구성

7) Omdia(2024. 7) 및 Omdia(2024. 12) 데이터를 기반으로 분석하였다.

그림 4 전세계 클라우드/데이터 센터 AI반도체 수요처별 시장전망(2023~2029)




주: 매출액 기준임

출처: Omdia(2024. 7) 기반 저자 재구성

On-device AI 반도체의 수요처는 PC & Tablet, Smart-Phone, Smart-Speaker, Security-camera, Machine-vision, Drone, Automotive, Robotics, Edge-sever, Head-Mounted-device 등으로 다양하다. On-device AI 반도체분야도 채택률이 높은 스마트폰과 PC및 태블릿이 전체 시장의 약 80%를 차지하고 있을 정도로 특정 분야에 의존도가 높으나, 나머지 다양한 분야의 AI 반도체 침투율은 낮아 향후 성장이 지속될 것으로 기대된다. 2029년 기준 세부 수요처별 AI 반도체 침투율을 살펴보면, PC 및 태블릿과 스마트폰이 각각 84%, 73%에 포화 수준에 근접하나, 자동차, 보안 카메라, 로봇 등의 분야는 각각 27%, 44%, 53%로 낮은 수준일 것으로 전망된다.


그림 5 전세계 On-device AI 반도체 수요처별 시장전망(2023~2029)



주: 매출액 기준임

출처: Omdia(2024, 7) 기반 저자 재구성

그림 6 전세계 On-device AI 반도체 수요처별 침투율(2022~2029)



주: 분야별 기기에서 AI반도체 탑재한 비율

출처: Omdia(2024, 12)

AI 반도체 제품별 비중을 살펴보면, 클라우드·데이터 센터 AI반도체 시장은 2023년 기준 GPU 기반 AI 반도체가 73.7%에 달할 정도로 GPU 중심 시장으로, Nvidia는 2023년 기준 클라우드·데이터 센터 AI 반도체 시장은 71.9%의 시장점유율을 차지하고 있을 정도⁸⁾로 GPU에 대해 압도적인 경쟁력을 보유하고 있어 스타트업 뿐만 아니라 기존 업체도 새로운 시장 기회를 창출하기 어려운 구조이다.

그러나, On-device AI 반도체 시장의 경우, 2023년 기준 스타트업의 진출이 쉬운 AI 반도체 분야인 NPU에 해당하는 Proprietary-core AI ASSP 및 AI ASIC의 비중도 약 40%에 달해 새로운 기회를 제공하고 있다. 특히, 제품별로는 GPU 비중이 높은 PC 또는 태블릿, 스마트폰과 달리 자동차, 로봇 등 Physical AI 기기에는 NPU 비중이 높아 성장성이 높다고 할 수 있다.

표 3 전세계 클라우드/데이터 센터 AI반도체 시장 프로세서 제품별 비중 (2023 vs 2029)

구분	2023년 비중	2029년 비중
GPU-derived AI ASSP	73.7%	71.0%
AI ASIC	9.5%	24.9%
In-CPU accelerator	8.5%	2.0%
Proprietary-core AI ASSP	6.3%	1.8%
FPGA	2.0%	0.2%
전체	100.0%	100.0%

주: 매출액 기준임
출처: Omdia(2024, 7) 기반 저자 재구성

표 4 전세계 On-device AI반도체 시장 프로세서 제품별 비중 (2023 vs 2029)


구분	2023년 비중	2029년 비중
GPU-derived AI ASSP	47.7%	50.9%
Proprietary-core AI ASSP	24.1%	25.4%
AI ASIC	18.4%	13.8%
FPGA	2.3%	6.3%
In-CPU accelerator	7.5%	3.6%
전체	100%	100%

주: 매출액 기준임
출처: Omdia(2024, 12) 기반 저자 재구성

8) Omdia(2024, 7)


그림 7 전세계 On-device AI반도체 수요처별 제품 구성(2022~2029)

[GPU의 비중이 높은 수요처 예: PC 및 태블릿]



자료: Omdia(2025. 1)

[NPU의 비중이 높은 수요처 예: 자동차]



자료: Omdia(2025. 1)

4. Physical AI 구현을 위한 On-device AI 반도체 기업 전략

On-device AI 반도체 시장에는 Nvidia, Qualcomm, AMD, Intel 등의 주요 반도체 기업이 경쟁하고 있다. 이러한 주요 반도체 기업 중 Data-center 중심의 AI 반도체 분야에서는 Nvidia가 Physical AI를 구현하기 위하여 On-device AI 반도체 분야에 적극적으로 진출하고 있다. 또한 모바일 반도체 분야에서는 Qualcomm이 On-device AI 반도체 사업을 활발하게 추진하고 있다. 우리나라도 주요 반도체 중소기업 및 신생기업이 Physical AI가 제공하는 새로운 시장 기회인 On-device AI 반도체 사업 진출을 모색하고 있다.


가. 해외: NVIDIA & Qualcomm

□ NVIDIA

NVIDIA는 기존 생성형 AI를 위한 학습과 추론을 지원하는 Data-center 중심의 AI 반도체 사업을 운영하고 있다. 하지만 최근에는 Physical AI를 구현하기 위하여 On-device AI 반도체인 Hardware와 지원 기술 계층인 Software-tool을 밀접하게 결합하는 전략을 수립하여 적극적으로 실행 중이다. 기존 고성능 AI 반도체 기술을 클라우드에서 Edge 및 Device까지 확장하면서, 로봇, 자율주행차, 임베디드 시스템, 산업용 IoT 등을 목표로 Physical AI 구현을 강조하고 있다.

On-device AI 반도체 경우, NVIDIA Jetson 시리즈(AI 반도체+On-Board module)인 고성능·저전력 기능의 Orin, Xavier, TX2, Nano 등의 제품을 통해 다양한 수요처(Robotics, Drones, Smart Cameras, IoT ...)에 대응하고 있다.

그림 8 Nvidia의 On-device AI 반도체 Jetson 시리즈



출처: Nvidia 웹페이지, <https://www.nvidia.com/ko-kr/autonomous-machines/>

동시에 NVIDIA Jetson 시리즈의 지원 기술 계층인 NVIDIA JetPack SDK를 동시에 제공하고 있다. NVIDIA JetPack SDK는 Jetson 시리즈(Orin, Xavier, TX2, Nano 등)의 On-device AI 반도체에서 AI 애플리케이션의 개발과 실행을 지원한다.

표 5 Nvidia의 On-device AI 반도체 지원 기술 계층 JetPack SDK

주요 구성 요소	설명
CUDA Toolkit	병렬 처리용 GPU 프로그래밍 툴킷
cuDNN	딥러닝용 고성능 라이브러리
TensorRT	AI 추론 최적화 및 가속 라이브러리
DeepStream SDK	실시간 비디오 스트리밍 AI 분석 플랫폼
NVIDIA Container Runtime	Docker 기반 컨테이너 실행 환경

출처: Nvidia 웹페이지, <https://developer.nvidia.com/embedded/jetson-modules>

이러한 NVIDIA Jetson 시리즈와 NVIDIA JetPack SDK를 제공하는 데 있어 Nvidia와 다양한 관련 파트너가 협업 생태계(Jetson Ecosystem Partners)를 구축하여 지원하고 있다.


□ Qualcomm

Qualcomm은 모바일용 반도체를 중심으로 사업을 운영하고 있으며, 이러한 경쟁력을 바탕으로 On-device AI 반도체인 하드웨어 및 지원 기술 계층인 Software solution 제공을 통해 전략적 입지를 확보하고 있다. 이 외에도 AI 추론을 담당하는 Data-center 중심의 AI 반도체인 클라우드 AI 100 출시하였다.

Qualcomm의 On-device AI 반도체의 경우, 고성능의 에너지 효율적인 AI 추론 기능(energy-efficient AI inference directly on-device)을 강조하면서 Qualcomm Hexagon NPU, Qualcomm Adreno GPU, Qualcomm CPU, Qualcomm Sensing Hub 등 Qualcomm 이 보유하고 있는 AI Engine의 기술 조합으로 구성된다.

구체적인 On-device AI 반도체 경우, Snapdragon mobile, Snapdragon X Series, Snapdragon Digital Chassis, Qualcomm AI On-Prem Appliance 등의 제품을 통해 다양한 수요처(스마트폰, 자동차, XR 헤드셋 및 안경, PC, 산업용 IoT ..)에 진출하고 있다.⁹⁾

그림 9 Qualcomm의 On-device AI 반도체를 위한 AI Engine



출처: Qualcomm 웹페이지, <https://www.qualcomm.com/products/technology/processors/ai-engine>

9) Qualcomm(2025)

주요 구성 요소	설명
AI Frameworks	텐서플로우, 파이토치, 온닉스, 케라스
AI Runtimes & Inference Engine	Qualcomm 신경 처리 SDK, Qualcomm AI 엔진
Developer libraries and Services	프로그래밍 언어, 컴파일러, 에뮬레이션 지원
System software	시스템 인터페이스, SOC 가속기 드라이버

출처: Qualcomm 웹사이트, <https://www.qualcomm.com/developer/artificial-intelligence>

또한 Qualcomm On-device AI 반도체의 기능과 성능을 최대한 활용하기 위해 지원 기술 계층으로 Qualcomm AI Stack을 제공한다. Qualcomm AI Stack에는 AI 모델 배포를 간소화하고 성능을 향상하는 라이브러리, SDK 및 최적화 도구가 포함되어 있다. 개발자는 이러한 자원을 활용하여 Qualcomm On-device AI 반도체에 맞게 AI 모델을 효율적으로 조정하고 AI 기반 애플리케이션의 개발 및 출시 기간을 단축할 수 있다.


나. 국내

넥스트칩, 텔레칩스, 딥엑스, 모빌린트 등 우리나라 중소기업 및 스타트업은 다양한 On-device에 자체 개발한 AI 반도체와 이를 지원하는 SW 포함 최적화 기술을 동시에 제공하고 있다. 이를 위해 반도체 설계에 역량을 더불어 시스템 소프트웨어, 응용프로그램 개발 등 최적화에 많은 자원을 투입 중이다. 하지만 AI 반도체 기업이 제공하는 AI 반도체 최적화를 위한 이러한 지원 기술 계층은 자사 칩에 최적화되어 있어 상호 호환성과 새로운 영역으로의 확장에 한계가 있다.

차량 분야의 On-device AI 반도체를 개발하는 넥스트칩은 2024년 데이터 처리가 가능한 자율주행 칩을 제공하고 있다. NPU · GPU · CPU · ISP 엔진으로 구성되어 적용 위치에 따라 주행 또는 스마트 주차 기능을 수행하며, 주변 센서류와 연계를 위한 인터페이스 지원하는 제품으로 APACHE6를 개발했다. 텔레칩스는 2025년 3월 센서 인터페이스, 데이터 전처리, AI 가속 기능을 단일 칩셋에 통합하여 AI 연산 성능을 극대화한 A2X를 개발했다.¹⁰⁾

10) 텔레칩스(2025. 3. 6)

그림 10 넥스트칩: 자율주행 엣지 SoC

APACHE 4	APACHE 5	APACHE 6
ADAS 및 AD 어플리케이션 엣지 프로세서	1.6TOPs NPU가 내장된 딥러닝 기반 엣지 프로세서	자율주행 시스템(AVP)용 도메인 컨트롤러
(+) 컴퓨터 비전(CV) 알고리즘 기반 저전력 고효율 센싱 기술을 하나의 칩으로 실현 (초소형 패키지) (+) 엣지화를 통해 고성능 구현 및 실시간 연산처리 가능 (+) ECU 부하 감소를 통한 가격 경쟁력 확보	(+) 자사의 영상처리기술(ISP)와 ARM의 고성능 쿼드코어 CPU 결합 (+) 딜레이 없는 실시간 CNN 인퍼런스 기반 딥러닝 기술 연산이 가능한 전용 프로세서 NPU 내장	(+) 카메라 어플리케이션 탑재가 아닌 차량의 중앙 시스템에서 기능 수행 (+) 최대 8채널 카메라 입력이 가능 (+) 주변 센서류와의 퓨전을 위한 인터페이스 지원
 Etc info.	 Etc info.	 Etc info.

자료: 삼성증권(2024. 12)

딥엑스와 모빌린트는 엣지 서버의 데이터 처리와 Device에서 추론을 지원하는 AI 반도체에 중점을 두고 있다. 딥엑스는 실시간 객체 인식과 영상 분석 등 카메라 기반 AI 연산을 Edge 단계에서 수행할 수 있도록 설계한 NPU인 DX-MI 양산을 위해 검증을 시행하고 있다. 이 외에도 독립형 칩인 DX-V3는 이미지, 비디오 및 3D 포인트 클라우드 데이터처리가 필요한 자율주행, 로봇 비전에 특화되어 있다. 또한, 고객 맞춤형 딥엑스 NPU에서는 고객사의 AI 알고리즘을 바로 구동할 수 있는 SDK인 DXNN을 제공하고 있다.

모빌린트는 기업이나 공장 내 데이터 센터의 특정 서버나 PC에서 데이터를 처리할 수 있도록 딥러닝 알고리즘에 최적화된 ASIC 아키텍처를 채택한 NPU인 에리스를 제공한다. 동시에 지원 기술 계층인 SDK를 같이 제공한다. 또한, 모빌린트는 서버 없이 드론, 로봇, 스마트 카메라, AI CCTV 등 Device 내부에서 추론 작업을 수행할 수 있도록 CPU, AI 엔진 및 USB, 이더넷, MIPI 등 데이터 인터페이스가 내장된 개별 On-device AI 반도체인 레굴러스를 개발해 2026년에 양산할 계획이다.

그림 11 딥엑스: 엣지 AI반도체

			
DX-M Series	DX-M Series	DX-V Series	DX-M Series
DX-M1	DX-M1M (Coming Soon)	DX-V3 (Coming Soon)	DX-M2 (Coming Soon)
Type: AI Accelerator	Type: AI Accelerator	Type: AI Vision SoC	Type: GenAI Accelerator
AI Perf: 25 TOPS / 3~5W	AI Perf: 25 TOPS	AI Perf: 13 TOPS	AI Perf: TBU

자료: 딥엑스 웹사이트, <https://deepx.ai/products/ai-chips/>

Ⅲ. Physical AI 구현을 위한 국내 On-device AI 반도체 정책 현황

우리나라 정부는 2024년 AI 반도체 정책을 시행하기 위하여 AI-반도체 이니셔티브 전략(2024. 4. 25)을 발표하며, AI 반도체 중심의 종합적인 지원 계획을 수립하였다.

그림 12 AI-반도체 이니셔티브(안)의 9대 기술 혁신 과제



자료: 관계부처 합동(2024. 4. 25)

AI-반도체 이니셔티브 전략의 9대 기술혁신 과제 중 Physical AI 구현을 위한 국내 On-device AI 반도체 관련 과제로는 ⑦ AI 슈퍼컴퓨팅(K-클라우드 2.0 등) 및 ⑧ 온디바

이스 AI 과제가 있다. 각각의 과제는 현재 과기정통부와 산업부가 중심이 되어 데이터센터 및 특정한 애플리케이션에 활용되는 다양한 AI 반도체를 개발·지원할 계획이다. 동시에 부처 공통으로 지원 기술 계층 영역인 ⑨ 차세대 개방형 AI 아키텍처·SW 과제를 중심으로, AI반도체를 데이터센터와 온디바이스 AI에 효과적으로 적용하기 위한 한국판 차세대 개방형 AI 아키텍처·SW에 대한 투자를 강화할 계획이다.

□ 과학기술정보통신부¹¹⁾¹²⁾

과학기술정보통신부의 AI 반도체 정책은 주로 생성형 AI를 위한 학습과 추론을 지원하는 Data-center 중심의 AI 반도체 기술개발 사업에 집중되고 있지만, On-device AI 반도체를 출시하여 본격적으로 시장에 진출하고자 하는 기업을 지원하는 실증 사업도 추진하고 있다.

과학기술정보통신부는 2025년 국가전략자산인 AI 컴퓨팅 인프라 경쟁력 확보를 위해 국산 AI 반도체 기반의 AI 컴퓨팅 HW·SW 핵심기술을 개발하는 『K-클라우드 기술개발사업』을 계획 및 실행하고 있다.

주요 전략 과제로 ① AI 반도체 데이터센터 인프라 및 HW, ② AI반도체 데이터센터 컴퓨팅 SW, ③ AI 반도체 특화 클라우드 기술 등 3대 전략 분야 11대 중점 기술 개발(28개 과제) 등을 수행할 예정이다.

그림 13 K-클라우드 사업의 3대 전략분야 11대 중점기술 현황



출처: 과기정통부(2025. 5. 8)

11) 과기정통부(2025. 5. 8)

12) 과기정통부(2025. 6. 10)

이 외에도 과학기술정보통신부는 2025년 인공지능 반도체 실증 추경사업을 통해 ① 인공지능 컴퓨팅 실증 기반(인프라) 고도화, ② 인공지능 전환 실증 지원, ③ 인공지능 반도체 사업화 적시 지원, ④ 인공지능-반도체 해외 실증 지원, ⑤국산 인공지능 반도체 기반 기기(디바이스) 인공지능 전환 개발·실증을 수행할 예정이다.

표 7 2025년 인공지능 반도체 실증 추경사업 편성 내용

구분	주요 내용
인공지능 컴퓨팅 실증 기반(인프라) 고도화	• 국산 신경망 처리 장치(NPU) 기반 인공지능(AI) 컴퓨팅 실증 기반 구축('25년 50PF, 3년간 120PF) 및 거대언어모형(LLM) 실증('26~)
인공지능 전환 실증 지원	• 기 상용화된 인공지능 서비스·기기의 그래픽 처리장치(GPU) → 신경망 처리 장치(NPU) 전환 실증 및 상용화 지원
인공지능 반도체 사업화 적시지원	• 설계 소프트웨어, 제품 제작, 검증 등 사업화 단계별 지원
설계 소프트웨어	• 고성능 설계 소프트웨어 이용권(SW 바우처) 지원 및 전문 엔지니어 기술지원
제품 제작지원	• (시제품) 시제품 칩 파운드리 비용 지원 등 시제품 제작 종합 지원 • (양산품) 소프트웨어 개발, PCIe 카드 및 보드 구현 등 양산품 수준 제품구현 지원
검증체계 구축	• 설계 디자인 검증 및 보드/서버 레벨 단위의 안정성·신뢰성 등 종합검증 지원
인공지능-반도체 해외실증	• 인공지능 반도체 기반 서버/기기+인공지능 모형을 꾸러미화하여 해외 현지 수요처 실증 지원
국산 인공지능 반도체 기반 기기(디바이스) 인공지능 전환 개발·실증	• 국산 신경망 처리 장치(NPU) 기반 기기 고도화 및 인공지능 서비스 개발 등을 위한 기술지원

출처: 과기정통부(2025. 6. 10)

□ 산업통상자원부¹³⁾

산업통상자원부는 2025년 자동차, IoT·가전, 기계·로봇, 방산 등 4대 분야 반도체 수요·공급 기업들과 『K-온디바이스 AI 반도체 기술개발 사업』 계획을 발표했다. 본 사업은 2026년 사업 착수를 목표로, 2025년 중 예비타당성 조사 면제 신청 등 관련 절차를 거쳐, 2026년 예산 확보를 추진 중이다.

이미 국내 산업은 자동차·가전 등 업종별 AI가 접목될 Physical AI 수요분야와 이를 구현하는 On-device AI 반도체 제조의 파운드리 분야에서 글로벌 수준의 기업들을 보유 중이다. 따라서 산업부는 수요기업을 중심으로 반도체 업계와 On-device AI 반도체 생태계

13) 산업부(2025. 5. 20)

를 함께 구성해, Physical AI 시대를 선도해 나가도록 지원할 계획이다.

특히 본 사업은 자동차, IoT·가전, 기계·로봇, 방산 분야 등 4대 분야별 On-device AI 반도체와 SW, 모듈, AI 모델 등의 지원 기술 계층(Full stack)을 개발·실증한다. 그리고 이러한 4대 분야 수요기업과 국내 팹리스, SW기업이 협력체를 구성해 수요 맞춤형 On-device AI 반도체와 SW를 개발·실증하고, 나아가 탑재와 양산까지를 목표로한다.

표 8 K-온디바이스 AI 반도체 기술개발 사업 계획

업종		주요내용
	자동차	▶(개발내용) SDV 기반 자율주행을 위한 온디바이스 AI 반도체 솔루션 개발 ▶(예시) 통신이 불안정한 터널, 재난 상황에서 예측 불가한 사고 상황을 외부 정보 없이도 자체적으로 실시간 학습하여 자율주행
	IoT·가전	▶(개발내용) 스마트 홈을 위한 온디바이스 AI반도체 솔루션 개발 ▶(예시) 가족 구성원별로 음성·행동패턴 등을 스스로 학습·인지해 연결된 가전의 불륨·조도·습도를 조절하는 등 사용자 맞춤 최적의 실내 환경 조성
	기계·로봇	▶(개발내용) 협동로봇을 위한 온디바이스 AI반도체 솔루션 개발 ▶(예시) 작업환경 변화 학습 기반 협동 로봇의 정밀작업, 효율적인 협업 지원 ▶(개발내용) 휴머노이드를 위한 온디바이스 AI반도체 솔루션 개발 ▶(예시) 사용자의 습관과 감정을 실시간으로 인지해 맞춤형 돌봄 서비스 제공 ▶(개발내용) 무인 농기계를 위한 온디바이스 AI반도체 솔루션 개발 ▶(예시) 무인 트랙터가 실시간으로 토지상태를 파악해 파종, 작물성장도 고려해 수확
	방산	▶(개발내용) 공중 무인플랫폼(드론, 무인기 등)용 온디바이스 AI반도체 솔루션 개발 ▶(예시) 전시에 무인기가 통신 연결 없이도 자체 판단해 목표물을 정밀 타격

출처: 산업부(2025. 5. 20)

□ 중소벤처기업부

중소벤처기업부는 「초격차 스타트업 1000+ 프로젝트」(DIPS 1000+)를 통해 2023부터 2027년까지 5년간 AI, 시스템반도체 등 10대 신산업 분야에서 국가 경제의 미래를 이끌어갈 우수 딥테크 스타트업 1,000개 이상을 선정하고 집중 지원을 통해 글로벌 유니콘으로 육성하는 프로젝트를 수행하고 있다. 2024년까지 407개사를 선정하여 육성 중이다.¹⁴⁾

선정된 스타트업은 3년간 최대 6억 원의 사업화 자금과 기업 수요에 따라 별도 평가를 거쳐 최대 6억 원의 R&D 자금 등 총 11억 원의 자금을 직접지원 받고, 정책자금보증수출 등을 연계 지원받을 수 있다.

중소벤처기업부는 이러한 초격차 스타트업 1000+ 프로젝트의 세부 프로그램으로 Micro

14) 중기부(2025. 5. 13)

DIPS-AI 핵심 분야, Micro DIPS-팹리스 일관지원, Micro DIPS-초격차 챌린지 등을 통해 AI 반도체, On-device AI 및 SW 개발 역량을 보유한 스타트업을 지원하고 있다.

표 9 초격차 스타트업 1000+ 프로젝트 중 AI 반도체 지원 현황

• Micro DIPS AI 핵심 분야	지원대상	• 창업 10년 내 AI 스타트업
	내용	• AI 스타트업의 성장과 생태계 강화를 위해 소형 언어모델(sLLM) 등 고성장 분야 기술고도화 및 경제사회적으로 성과 창출이 용이한 제조콘텐츠 등 주요 산업 분야에서의 수요 기반 협업을 지원
• Micro DIPS 팹리스 스타트업 일관지원	지원대상	• 창업 10년 내 팹리스 스타트업
	내용	• 딥테크 인프라 통합과 고성장 분야(AI, 팹리스 등) 집중 지원을 통한 예비 DIPS 스타트업 육성
• Micro DIPS 초격차 챌린지	지원대상	• 창업 10년 내 팹리스 스타트업
	지원규모	• 2025년 챌린지는 ① LG전자, intel 등과 협업하는 ‘온디바이스 AI’와 ② 퀄컴과 퀄컴의 국내 파트너인 유망 딥테크 중소벤처기업 4개사와 협업하는 ‘버티칼 AI’ 등 2개 프로그램으로 구성 • 향후 팹리스 스타트업과 국내 모든 파운드리가 협업하는 ‘팹리스 챌린지’ 계획

출처: 중기부(2025. 2. 5), 중기부(2025. 2. 11), 중기부(2025. 5. 2) 기반 저자 재구성

IV. Physical AI에 대응한 On-device AI 반도체 경쟁력 강화를 위한 정책 제언 및 시사점

AI 기술의 중심이 학습에서 추론으로 이동하고, 소형 AI 모델의 부상으로 On-device AI 방식의 Physical AI가 구현됨에 따라 On-device AI 반도체는 향후 AI 생태계의 중요한 축으로 자리매김할 것으로 예상된다. 따라서 AI 반도체 시장은 새로운 경쟁 국면에 접어들 전망이다.

이러한 변화에 대응하여 Nvidia, Qualcomm, AMD, Intel 등 주요 AI 반도체 기업들은 각자의 강점을 활용한 전략으로 시장 변화에 대응하고 있다. AI 반도체의 강자인 Nvidia는 기존 데이터센터용 AI 반도체 시장에서 경쟁력을 유지하는 동시에 새로운 성장 동력으로서 On-device AI 반도체 시장을 개척해 나가고 있다. Physical AI 구현을 위한 On-device AI 반도체 시장의 개척을 위해 지원 기술 계층, AI 반도체, AI 모델, 애플리케이션 개발 등을 플랫폼 방식으로 제공하고 있다.¹⁵⁾

또한 Qualcomm은 모바일 반도체 시장을 주도해 온 경험을 바탕으로, On-device AI 반

15) <https://developer.nvidia.com/isaac>

도체 시장에 주력하는 동시에 기존 데이터센터용 AI 반도체 시장으로의 사업영역 확장을 기획하고 있다. Qualcomm도 Nvidia와 같이 Physical AI 구현을 위한 On-device AI 반도체 시장의 경쟁력을 유지하기 위하여 지원 기술 계층, AI 반도체, AI 모델, 애플리케이션 개발 등을 플랫폼 방식으로 제공하고 있다.¹⁶⁾

하지만 기존 주요 반도체 업체가 자사의 On-device AI 반도체 제품과 기술 계층만으로는 다양한 수요처에 모두 대응하는 것은 불가능하므로 국내의 다양한 AI 반도체 대기업 또는 중소벤처 업체들이 집중해서 진출할 수 있는 최적의 분야로 판단된다.

따라서 우리나라의 Physical AI 구현을 위한 On-device AI 반도체의 경쟁력 강화 방향에는 주요 AI 반도체 업체의 플랫폼 전략처럼 다음과 같은 AI 반도체 생태계 구조화에 대한 지원을 염두에 두어야 한다.

첫째, On-device AI 반도체 수평적 가치사슬 영역별 참여 기업의 경쟁력이 부족한 부문에 세밀한 지원과 협력 네트워크가 필요하다. 기존 반도체 가치사슬에서 AI 반도체 설계 및 생산과 관련된 다양한 자원과 역량을 기업 외부에서 조달하거나, 협업 및 인수·합병해야만 하는 환경으로 변화되고 있다. 이러한 환경 변화에 대응하여 AI 반도체 참여 기업이 반도체 가치사슬 영역에서 새로운 기술을 흡수하고 활용할 수 있도록 정부의 정밀한 지원과 실질적이고 전략적인 협력 네트워크의 조성 및 확대가 필요하다.

둘째, On-device AI 반도체의 수요처가 다양해지고 다품종·소량 생산으로 변화될 전망이다. 이어서 이에 따른 수요처별 지원이 요구된다. On-device AI 반도체의 발전을 위해서는 최종 수요자의 종합 시스템(최종 제품 Set + 최종 서비스)에 맞춘 반도체 설계 역량이 중요하다. 따라서 다양한 수요처의 요구사항과 특성이 서로 다르므로 On-device AI 반도체 개발할 때 이러한 차이점을 이해하여 보다 차별화된 지원이 제공되어야 한다.

셋째, On-device AI 반도체의 활용에 필수적인 다양한 기술 계층에 대한 지원이 필요하다. 전력 효율성이 좋으면서 특화 연산 능력을 갖춘 AI 반도체의 최적화를 지원하는 다양한 기술 계층(시스템SW, SDK, 최적화 솔루션, 보완 시스템 반도체, AI 반도체 보드, 냉각 솔루션, 서버 공급 등)의 개발에 대한 투자와 이를 제공할 수 있는 다양한 파트너와 협력 네트워크를 구축하는 것이 필요하다.

마지막으로 정부의 AI 반도체 지원 정책은 관계 부처 합동으로 만들어진 최상위 국가 AI 전략 아래 지속적으로 업데이트 및 모니터링되는 거버넌스가 요구된다. 현재 국내 AI 반도체 지원 정책은 『AI-반도체 이니셔티브 전략』 계획을 중심으로 부처별 정책이 상호 배타

16) <https://aihub.qualcomm.com>

적이면서 구조화를 이루고 있다.

예를 들어 과기정통부는 데이터 센터용 AI 반도체 개발을 지원하는 『K-클라우드 사업』을 수행하고 있으며, 산자부는 On-device AI 반도체 개발을 지원하는 『K-온디바이스 AI 반도체 기술개발 사업』을 진행하고 있다. 중기부는 AI 반도체를 개발하는 팹리스 중심으로 지원하는 『초격차 스타트업 1000+ 프로젝트』를 수행하고 있다.

따라서 부처별 AI 반도체 지원 정책이 파편화되지 않고, 국가 AI 반도체 경쟁력 강화라는 최종정책 목표를 달성할 수 있도록 부처별 단위 정책의 시너지 효과를 강화하면서, 지속적으로 조정 및 모니터링하되 적극적으로 과감하게 정부 자원을 할당해 주는 거버넌스가 요구된다.

참고문헌

[국내 문헌]

관계부처 합동(2024. 4. 25), “AI-반도체 이니셔티브(안)”, 보도자료.

https://www.pacst.go.kr/jsp/m/initiative/ai_initiative_intro.pdf.

과기정통부(2025. 5. 8), “4천억 원 규모의 국산 인공지능 반도체 기반 한국형-인터넷기반 자원공유(K-클라우드) 기술개발 사업 본격 추진”, 보도자료,

<https://www.msit.go.kr/bbs/view.do?sCode=user&bbsSeqNo=94&nttSeqNo=3185781>.

과기정통부(2025. 6. 10), “과기정통부, 기업 소통을 바탕으로 국산 인공지능 반도체 상용화 지원 성과를 앞당긴다”, 보도자료,

<https://www.msit.go.kr/bbs/view.do?sCode=user&mPid=208&mId=307&bbsSeqNo=94&nttSeqNo=3185882>.

산업부(2025. 5. 20), “피지컬 AI 시대 선점 위해 4대 분야 「K-온디바이스 AI 반도체 개발」 본격 추진”, 보도자료, <https://www.motie.go.kr/kor/article/ATCL3f49a5a8c/170538/view>.

삼성증권(2024. 12), “넥스트칩”, https://www.samsungpop.com/common.do?cmd=down&contentType=application/pdf&inlineYn=Y&saveKey=research.pdf&fileName=2010/2024121108221156K_02_08.pdf.

삼정 KPMG 경제연구원(2024), “생성형 AI에게 펼쳐진 새로운 무대, 온디바이스 AI”, Issue Monitor 제165호,

<https://assets.kpmg.com/content/dam/kpmg/kr/pdf/2024/issue-monitor/kpmg-korea-on-device-ai-20240620.pdf>.

《연합뉴스》(2025. 1. 7), “CES 기조연설하는 엔비디아 젠슨 황 CEO”

<https://www.yna.co.kr/view/PYH20250107120200013>.

중기부(2025. 2. 5), “중소벤처기업부 공고 제2025-70호 2025년 초격차 스타트업 1000+ 프로젝트 Micro DIPS(핵심사업화, AX 육성) 창업기업 모집공고”,
<https://www.mss.go.kr/site/smba/ex/bbs/View.do?cbIdx=310&bcIdx=1056406&parentSeq=1056406>.

중기부(2025. 2. 11), “중소벤처기업부 공고 제2025-87호 2025년 초격차 스타트업 1000+ 프로젝트 Micro DIPS(캡리스 일관지원) 창업기업 모집공고”,
<https://www.mss.go.kr/site/smba/ex/bbs/View.do?cbIdx=310&bcIdx=1056520>.

중기부(2025. 5. 2), “중기부 창업지원 정책, ‘세계적 수준의(Global Top) 인공지능(AI) 창업기업(스타트업)’ 양성하다”, 보도자료,
<https://www.mss.go.kr/site/smba/ex/bbs/View.do?cbIdx=86&bcIdx=1058618>.

중기부(2025. 5. 13), “초격차 스타트업 지원 성과부터 글로벌 스케일업 전략까지 한자리에”, 보도자료,
<https://mss.go.kr/site/smba/ex/bbs/View.do?cbIdx=86&bcIdx=1058844>.

텔레칩스(2025. 3. 6), “텔레칩스, 차량용 AI 가속기 공개...” 미래차 AI 기술혁신으로 SDV 기반기술 강화”, 보도자료, <https://www.telechips.com/view/media/newsView>.

한국저작권위원회(2024), 온디바이스 AI 산업현황 보고서.

[해외 문헌]

CITI(2024). “The Rise of AI Robots, Physical AI is Coming for You”,
https://www.citifirst.com.hk/home/upload/citi_research/rsch_pdf_30297368.pdf.

Omdia(2024. 7). “AI Processors for Cloud and Data Center Forecast Report - 2024 Database”,
<https://omdia.tech.informa.com/collections/afcai002/ai-processors-for-cloud-and-data-center-forecast>.

Omdia(2024. 12). “AI Processors for the Edge Forecast Report - 2024 Database”,
<https://omdia.tech.informa.com/om122938/ai-processors-for-edge-forecast-report-2024-database>.

Omdia(2025. 1). “AI Processors for Edge Forecast Report - 2024 Analysis”,
<https://omdia.tech.informa.com/om122880/ai-processors-for-edge-forecast-report-2024-analysis>.

Qualcomm(2025). “AI disruption is driving innovation in on-device inference”,
<https://www.qualcomm.com/news/onq/2025/02/ai-disruption-is-driving-innovation-in-on-device-inference>.

[참고 웹사이트]

<https://aihub.qualcomm.com> (Qualcomm® AI Hub: 온-디바이스 AI 모델을 쉽고 빠르게 개발, 최적화, 배포할 수 있도록 지원하는 종합 플랫폼).

<https://deepx.ai/products/ai-chips/>.

<https://developer.nvidia.com/isaac> (NVIDIA Isaac platform: 로봇 개발을 위한 end to end full-stack 플랫폼).

<https://developer.nvidia.com/embedded/jetson-modules>.

<https://resources.nvidia.com/en-us-playlist-for-robotics/sensor-simulation>.

<https://www.nvidia.com/ko-kr/autonomous-machines/>.

<https://www.nvidia.com/en-us/glossary/generative-physical-ai/>.

<https://www.qualcomm.com/developer/artificial-intelligence>.

<https://www.qualcomm.com/products/technology/processors/ai-engine>.